Analyse des données de consommations d'énergie en Inde

Environnement de travail

```
library(tidyverse)
library(ggplot2)
library(readxl)
library(tidyr)
library(fda)
```

Notre base de données

Notre étude porte sur l'analyse de la consommation d'énergie dans les 33 Etats d'Inde. Il est à noter que l'Inde est le troisième producteur et le troisième consommateur d'électricité au monde.

Importation des données

Dans un premier temps, nous allons importer les données.

```
data <- read.csv("long_data_2.csv", stringsAsFactors = T,sep = ";")

colnames(data) <- c("Etat", "Regions", "latitude", "longitude", "Date", "Consommation")
data <- data[,-c(3,4)]
summary(data)
```

```
##                 Etat       Regions                   Date        Consommation
##  Andhra Pradesh   :  498   ER :2490   01/01/2020 00:00:   33   Min.   :  0.3
##  Arunachal Pradesh:  498   NER:3486   01/02/2020 00:00:   33   1st Qu.:  6.7
##  Assam            :  498   NR :4482   01/03/2020 00:00:   33   Median : 64.5
##  Bihar            :  498   SR :2988   01/04/2020 00:00:   33   Mean   :103.1
##  Chandigarh       :  498   WR :2988   01/05/2020 00:00:   33   3rd Qu.:174.0
##  Chhattisgarh     :  498              01/06/2020 00:00:   33   Max.   :522.1
##  (Other)          :13446              (Other)         :16236
```

```
# View(data)
```

Grâce à ce résumé statistique, nous pouvons voir que les valeurs de nos données de consommation d'énergie sont assez étendues : elles sont comprises entre 0.3 et 522.1 Méga Units.

```
data$Etat[which.max(data$Consommation)]
```

```
## [1] Maharashtra
## 33 Levels: Andhra Pradesh Arunachal Pradesh Assam Bihar ... West Bengal
```

```
data$Etat[which.min(data$Consommation)]
```

```
## [1] Sikkim
## 33 Levels: Andhra Pradesh Arunachal Pradesh Assam Bihar ... West Bengal
```

En effet, certaines valeurs journalières sont très faibles (inférieures à 1) alors que d'autres sont 500 fois plus élevées. Par exemple, le Maharashtra qui présente certaines valeurs très importantes en opposition avec le Sikkim.

Concernant notre base de données, elle décrit la consommation d'énergie dans **33 Etats** d'Inde entre 2019 et 2020.
Nous avons 16 434 lignes, soit **498 points de mesure** par pays (498*33). Les données sont journalières, exprimées en Mega Units.

```
dim(data)
```

```
## [1] 16434     4
```

Choix de la période étudiée

Nous allons transformer notre variable Date au format date pour poursuivre l'étude correctement.

```
data$Date <- as.Date(data$Date, format = "%d/%m/%Y %H:%M")
str(data) # Vérification
```

```
## 'data.frame':    16434 obs. of  4 variables:
##  $ Etat       : Factor w/ 33 levels "Andhra Pradesh",..: 25 11 26 7 31 32 12 13 5 6 ...
##  $ Regions    : Factor w/ 5 levels "ER","NER","NR",..: 3 3 3 3 3 3 3 3 3 5 ...
##  $ Date       : Date, format: "2019-01-02" "2019-01-02" ...
##  $ Consommation: num  119.9 130.3 234.1 85.8 313.9 ...
```

Pour simplifier notre analyse, nous allons nous concentrer seulement sur l'année 2019 :

```
data <- data |>
  filter(Date <= as.Date("2020-01-02"))
```

On vérifie à présent que les données que l'on va analyser correspondent bien à la période choisie.

```
min(data$Date)
```

```
## [1] "2019-01-02"
```

```r
max(data$Date)
```

```
## [1] "2020-01-02"
```

Normalisation des données

Au départ, nous avons voulu normaliser les données par le nombre d'habitants de chaque Etat pour que les consommations aient le même impact dans notre étude. Cependant, cette méthode s'est révélée problématique car nous avons obtenu des valeurs très proches de zéro, ce qui aurait compliqué les calculs.

Nous avons donc choisi de réduire les données de consommation, en soustrayant la moyenne, pour continuer notre analyse avec données moins disproportionnées.

```r
moyenne_par_etat <- tapply(data$Consommation, data$Etat, mean)

normalized_energy <- data
for(i in 1:nrow(normalized_energy)){
  normalized_energy$Consommation[i] <- normalized_energy$Consommation[i] - moyenne_par_etat[normalized_
}
```

Suite à cette normailisation, nous pouvons observer une diminution importante des valeurs. Mais nous obtenons des valeurs de consommations négatives, ce qui pose problème pour l'interprétation de nos analyses. Nous allons donc travailler avec les valeurs initiales.

Représentations graphiques

Nous allons tout d'abord représenter simplement nos données pour pouvoir faire ressortir les informations importantes.

```r
ggplot(data, aes(x = Date, y = Consommation, color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie par Etat") +
  theme_minimal()
```

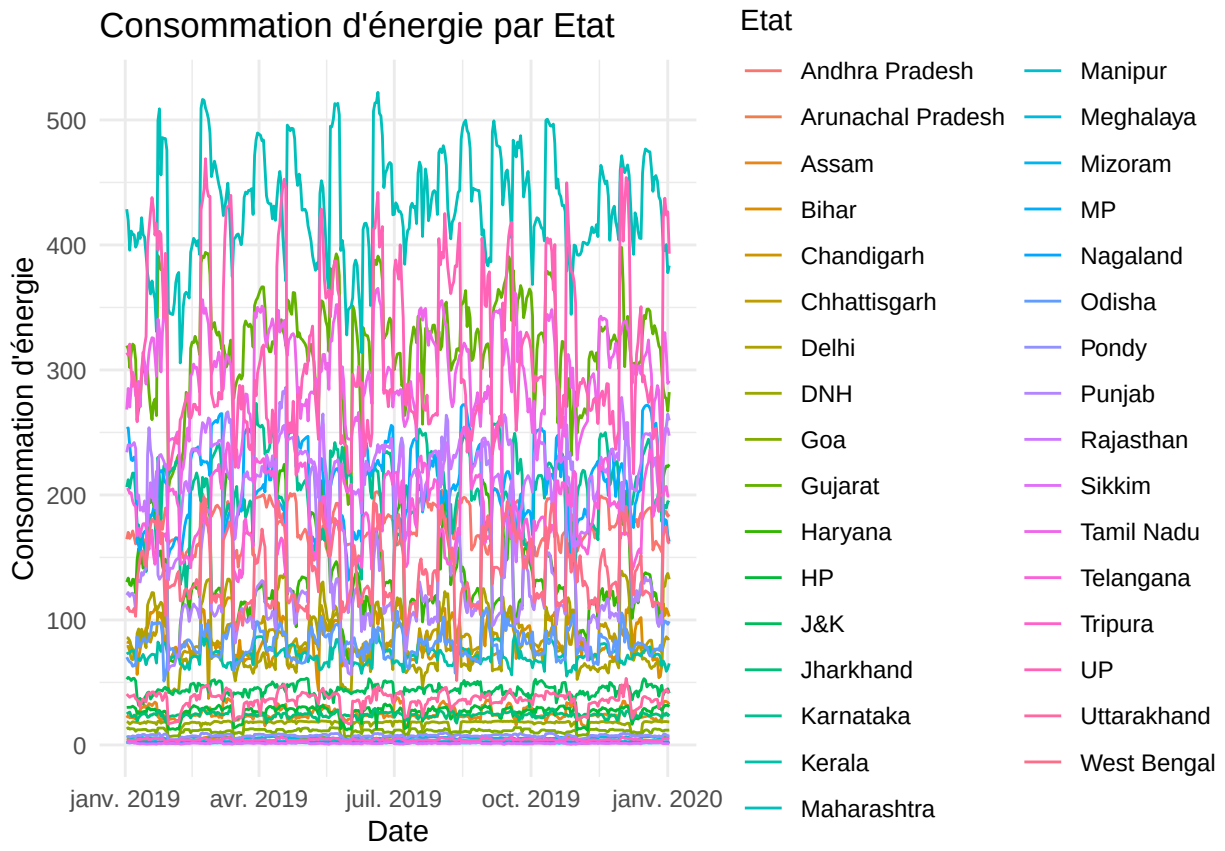

Ce graphique nous montre que nos données sont très irrégulières.

[Représentation des données en différentes parties].{underline}

Pour que les informations soient plus lisibles, nous avons décidé de séparer en plusieurs parties nos données. Nous avons fixé des seuils par rapport à la moyenne de consommations des Etats pour réaliser ces graphiques.

[Calcul de la moyenne par Etat].{underline}

On calcule d'abord la moyenne par Etat et on ajoute cette moyenne a un nouveau dataframe :

```
moyenne_par_etat <- tapply(data$Consommation, data$Etat, mean)
moyenne_par_etat <- data.frame(Etat = names(moyenne_par_etat), Moyenne = moyenne_par_etat)

data_complete <- merge(data,moyenne_par_etat, by = "Etat")
head(data_complete)
```

```
##             Etat Regions       Date Consommation  Moyenne
## 1 Andhra Pradesh      SR 2019-09-10        198.5 175.8916
## 2 Andhra Pradesh      SR 2019-09-09        201.3 175.8916
## 3 Andhra Pradesh      SR 2019-09-01        153.8 175.8916
## 4 Andhra Pradesh      SR 2019-01-11        167.7 175.8916
## 5 Andhra Pradesh      SR 2019-01-03        170.1 175.8916
## 6 Andhra Pradesh      SR 2019-09-19        193.5 175.8916
```

[Séparation de notre jeu de données].{underline}

On sépare les données en 3 catégories :

```r
data_inf <- data_complete |>
  filter(Moyenne <= 50)
# data_inf

data_moy <- data_complete |>
  filter(Moyenne > 50 & Moyenne < 200)
# data_moy

data_sup <- data_complete |>
  filter(Moyenne >= 200)
# data_sup
```

Représentations graphiques.{underline}

```r
ggplot(data_inf, aes(x = Date, y = Consommation, color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie par Etat", subtitle = 
  theme_minimal()
```

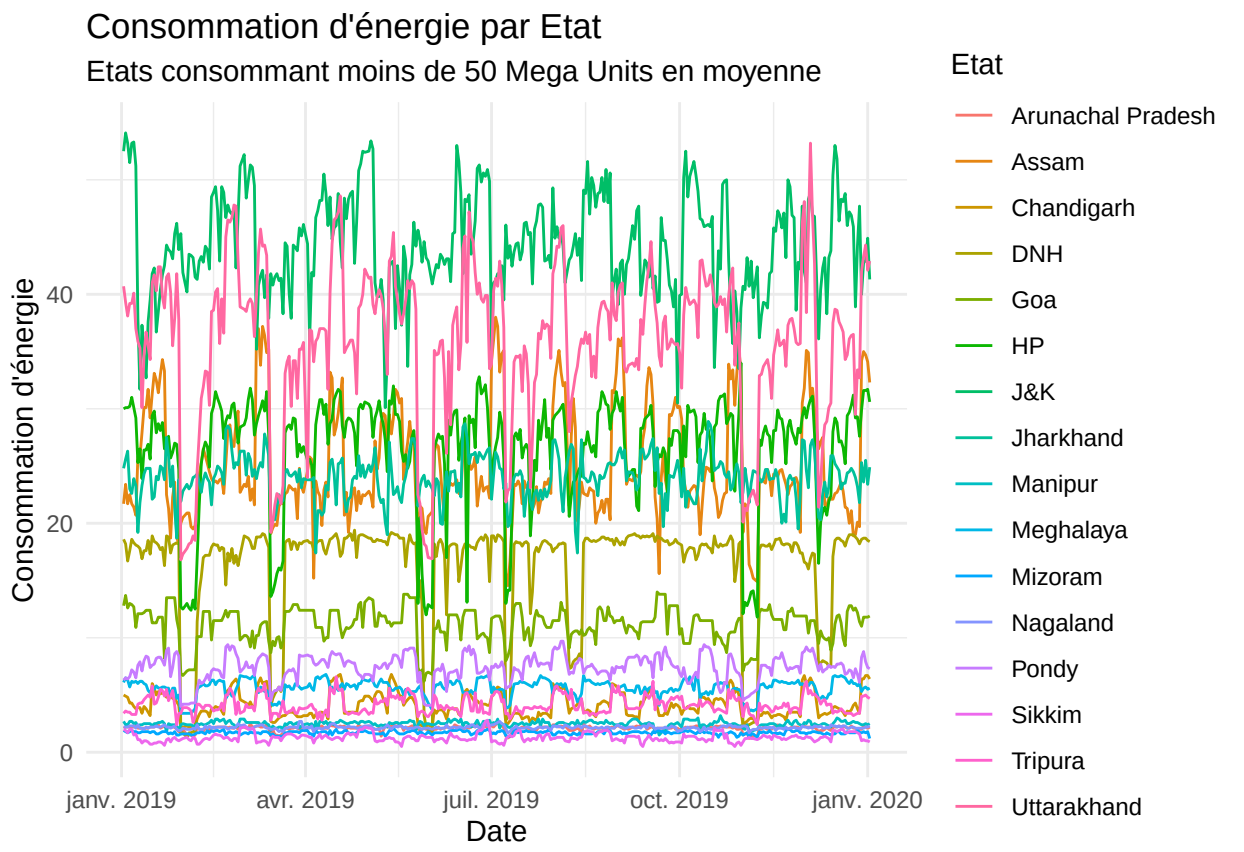


```r
ggplot(data_moy, aes(x = Date, y = Consommation, color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie par Etat", subtitle = 
  theme_minimal()
```

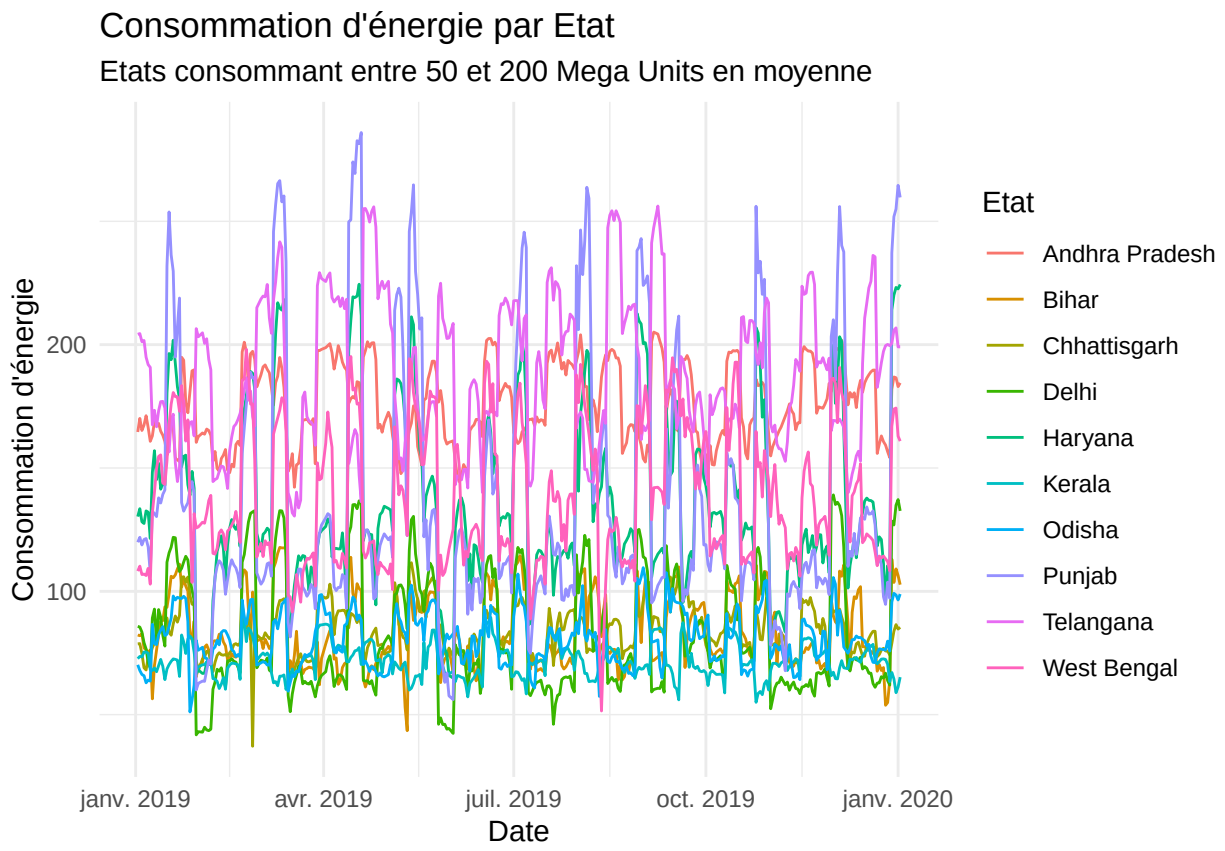


```
ggplot(data_sup, aes(x = Date, y = Consommation, color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie par Etat", subtitle = "
  theme_minimal()
```

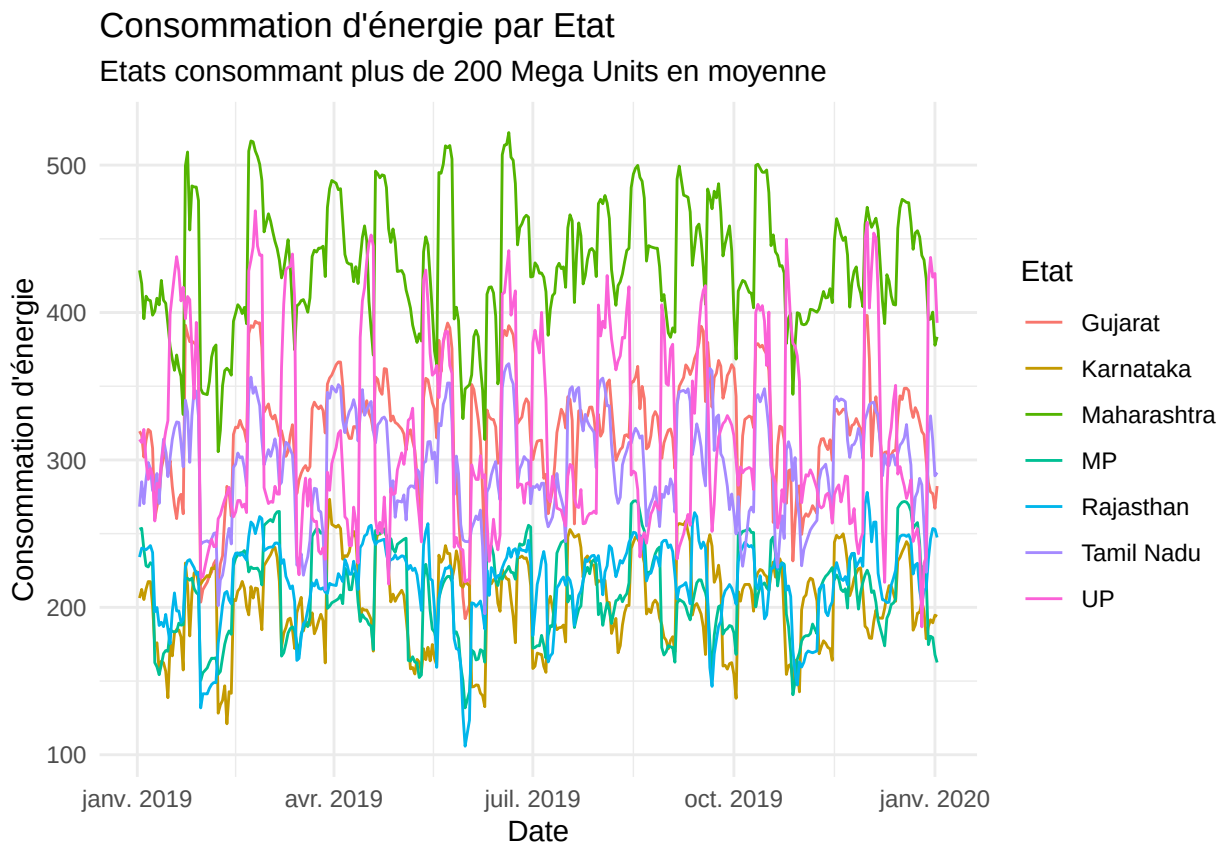

Grâce à ces représentations, il est plus facile d'observer et d'étudier l'allure de nos données.

Pour la plupart des Etats, leur consommation varie beaucoup tout au long de l'année et en quelques jours leur consommation peut doubler ou bien diminuer subitement.

Cependant certains Etats comme le Tripura possède une consommation très faible, et peu de variations dans son signal sont observées :

```
data |>
  filter(Etat=="Tripura") |>
  ggplot(aes(x = Date, y = Consommation)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie du Tripura") +
  theme_minimal()
```

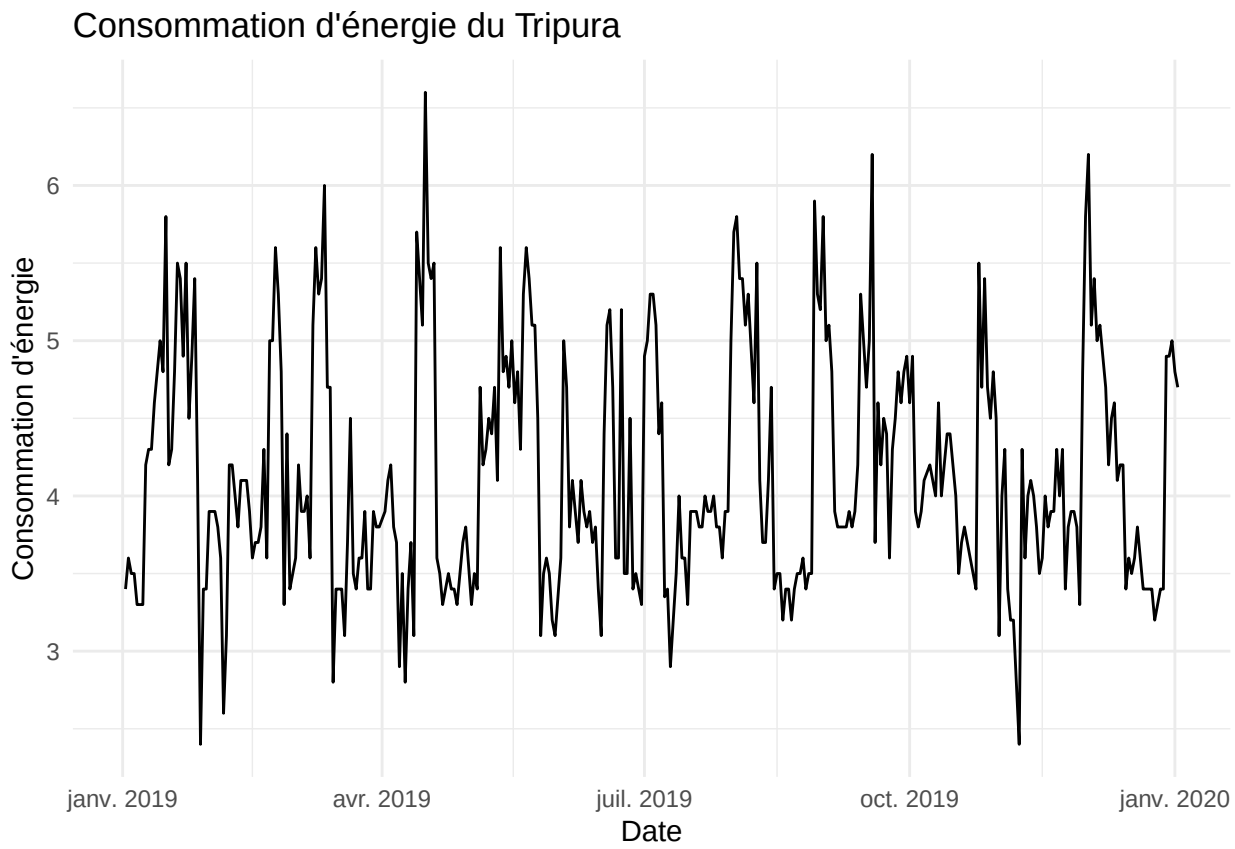

Sa consommation varie entre 2.4 et 6.6 mega Units.

```
min(data$Consommation[data$Etat=="Tripura"])
```

```
## [1] 2.4
```

```
max(data$Consommation[data$Etat=="Tripura"])
```

```
## [1] 6.6
```

A l'opposition du Punjab qui lui possède une très grande variation dans sa consommation :

```
min(data$Consommation[data$Etat=="Punjab"])
```

```
## [1] 56.1
```

```
max(data$Consommation[data$Etat=="Punjab"])
```

```
## [1] 286
```

Tableau des moyennes de consommation par Etat

```
knitr::kable(tapply(data$Consommation, data$Etat, mean),
             "simple",
             caption = "Tableau des moyennes des consommation par Etat",
             col.names = "Moyenne")
```

Table 1: Tableau des moyennes des consommation par Etat

	Moyenne
Andhra Pradesh	175.891573
Arunachal Pradesh	2.108146
Assam	25.156601
Bihar	83.878652
Chandigarh	4.132584
Chhattisgarh	84.220646
Delhi	82.659831
DNH	16.415590
Goa	11.183427
Gujarat	321.564747
Haryana	137.518258
HP	26.582303
J&K	44.331180
Jharkhand	23.998596
Karnataka	203.602247
Kerala	71.824298
Maharashtra	431.561517
Manipur	2.494101
Meghalaya	5.635674
Mizoram	1.712500
MP	208.722331
Nagaland	2.167416
Odisha	80.974438
Pondy	7.407865
Punjab	139.669522
Rajasthan	218.367977
Sikkim	1.296348
Tamil Nadu	297.655758
Telangana	188.360534
Tripura	4.145084
UP	314.962781
Uttarakhand	36.104494
West Bengal	139.527107

Représentation selon la région

L'Inde est divisée en 5 regions : le Nord (NR), Nord-Est (NER), le Sud (SR), l'Est (ER) et l'Ouest (WR) Nous allons tracer les consommations en fonction des régions (une couleur par région)./ De la même manière que les représentations précédentes, nous ne pouvons représenter les régions sur le même graphique. Sans diviser la représentation, il est difficile de bien observer les différences entre les régions.

Nous décidons donc de représenter une région par graphique :

```
data |>
  filter(Regions=="ER") |>
  ggplot(aes(x = Date, y = Consommation,color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie pour les Etats de l'Est
  theme_minimal()
```

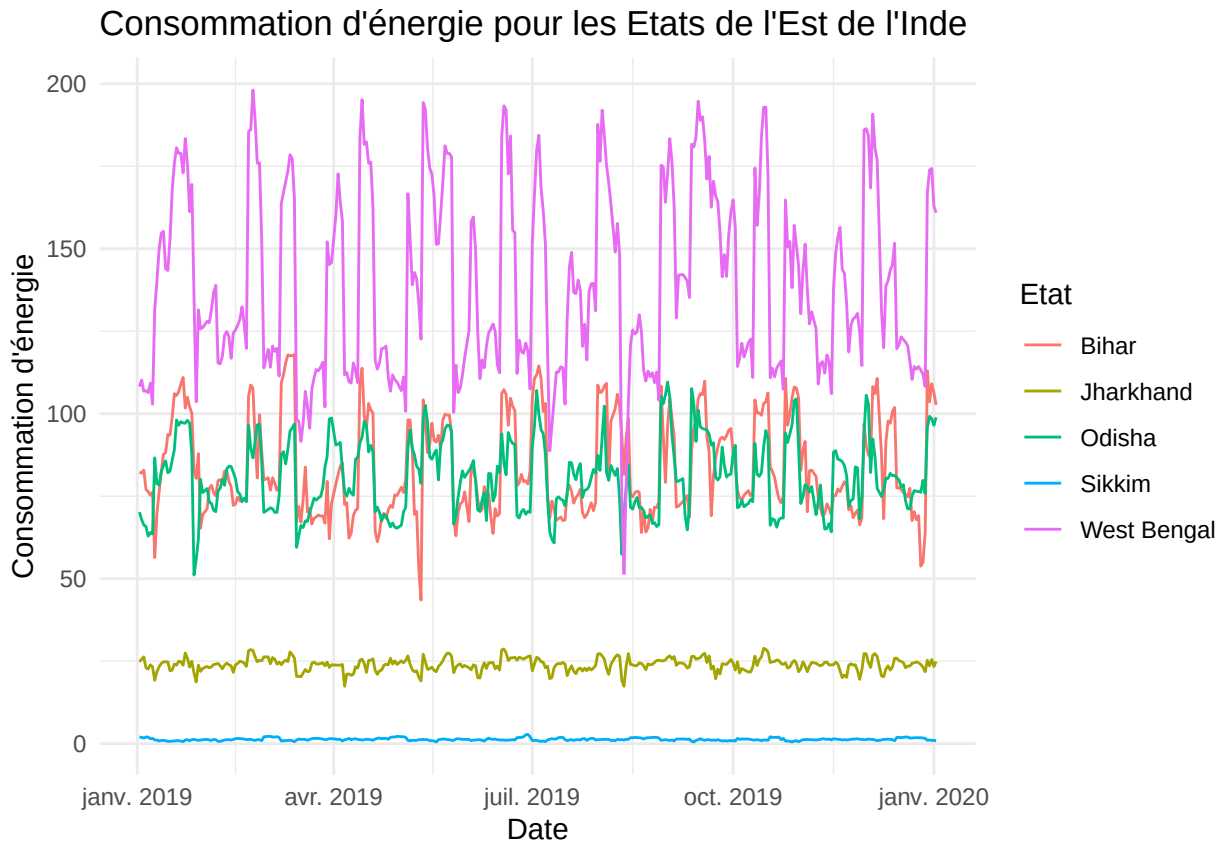


```
data |>
  filter(Regions=="NER") |>
  ggplot(aes(x = Date, y = Consommation,color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie pour les Etats du Nord
  theme_minimal()
```

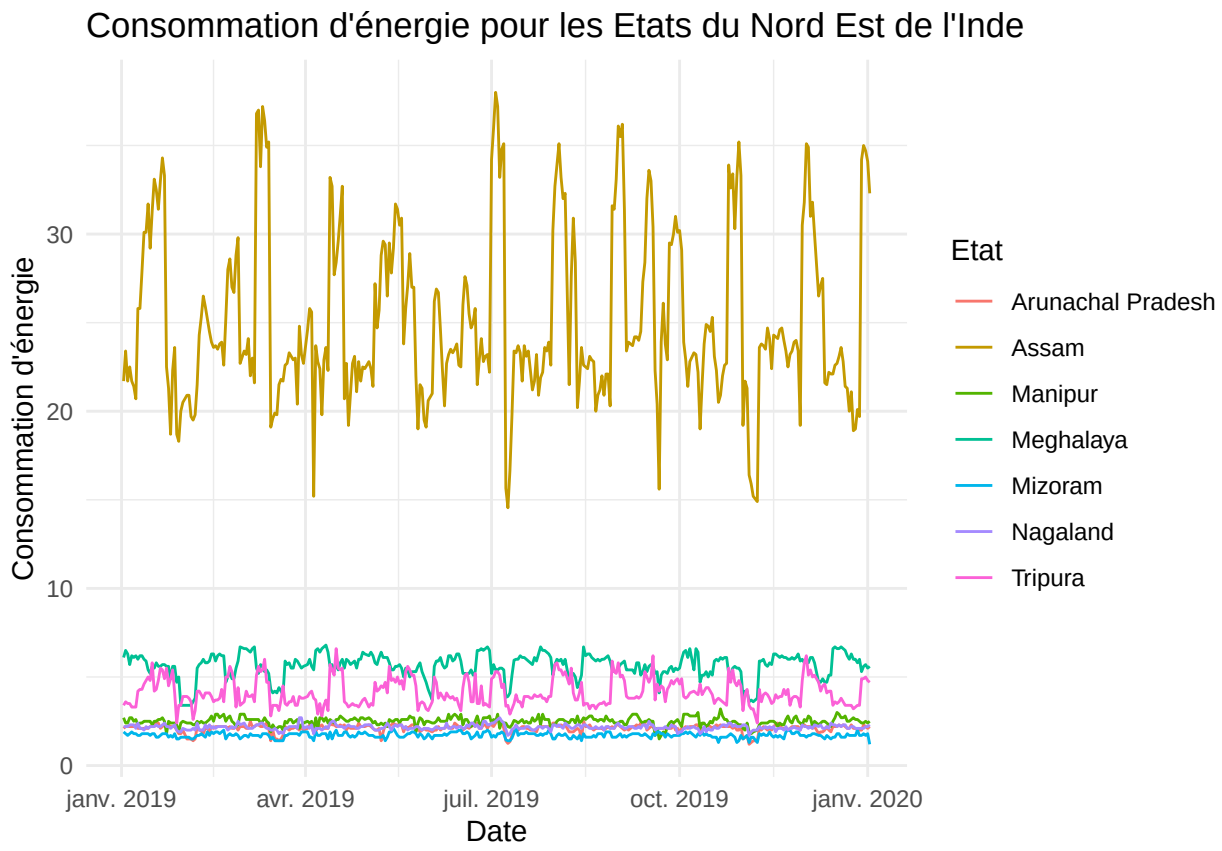


```
data |>
  filter(Regions=="NR") |>
  ggplot(aes(x = Date, y = Consommation,color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie pour les Etats du Nord
  theme_minimal()
```

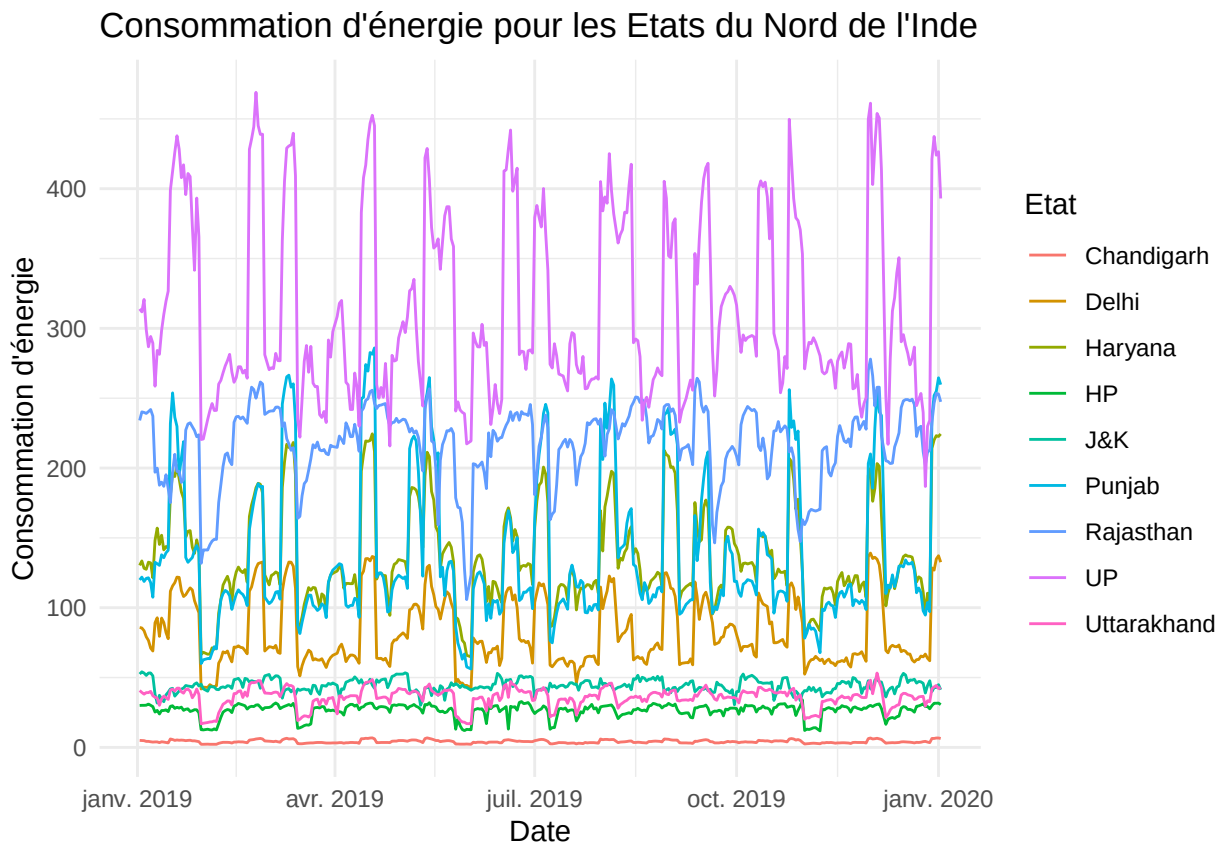


```
data |>
  filter(Regions=="SR") |>
  ggplot(aes(x = Date, y = Consommation,color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie pour les Etats du Sud
  theme_minimal()
```

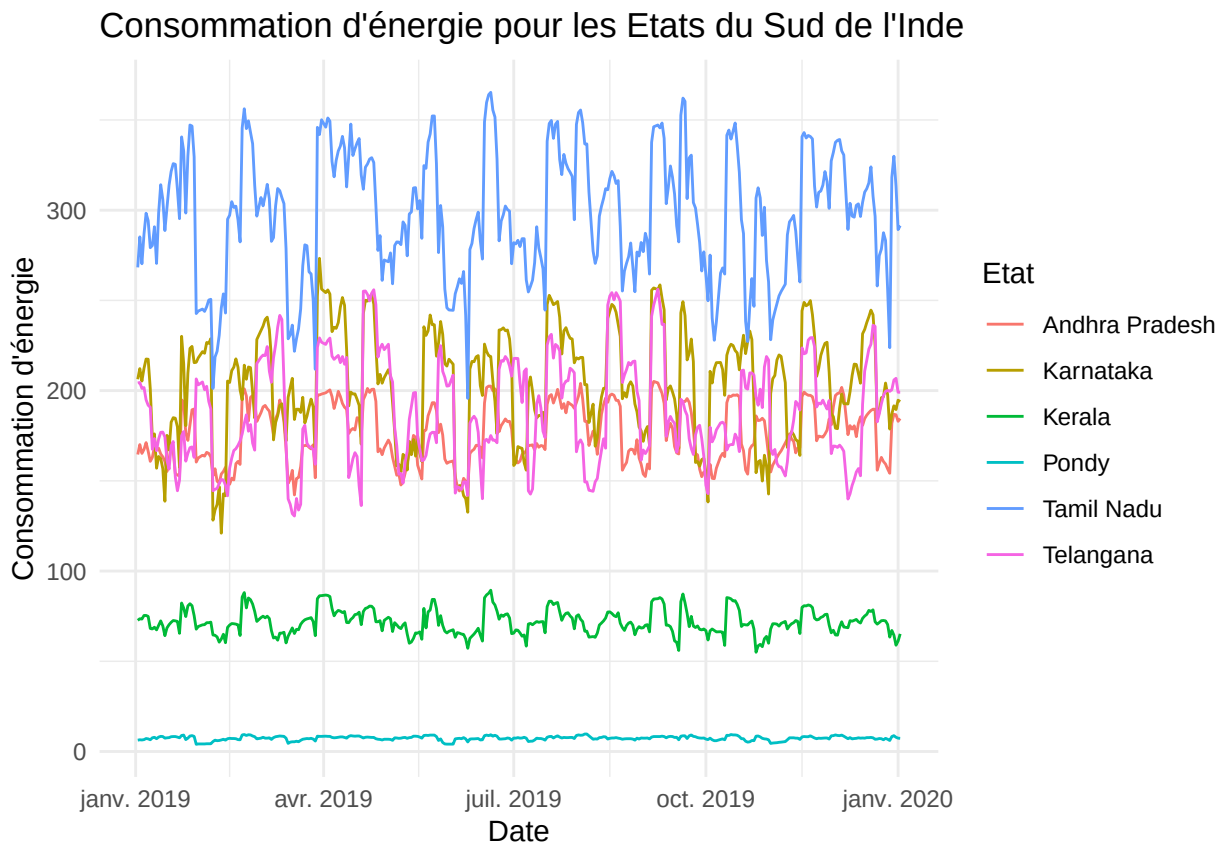


```
data |>
  filter(Regions=="WR") |>
  ggplot(aes(x = Date, y = Consommation,color = Etat)) +
  geom_line() +
  labs(x = "Date", y = "Consommation d'énergie", title = "Consommation d'énergie pour les Etats de l'Ou
  theme_minimal()
```

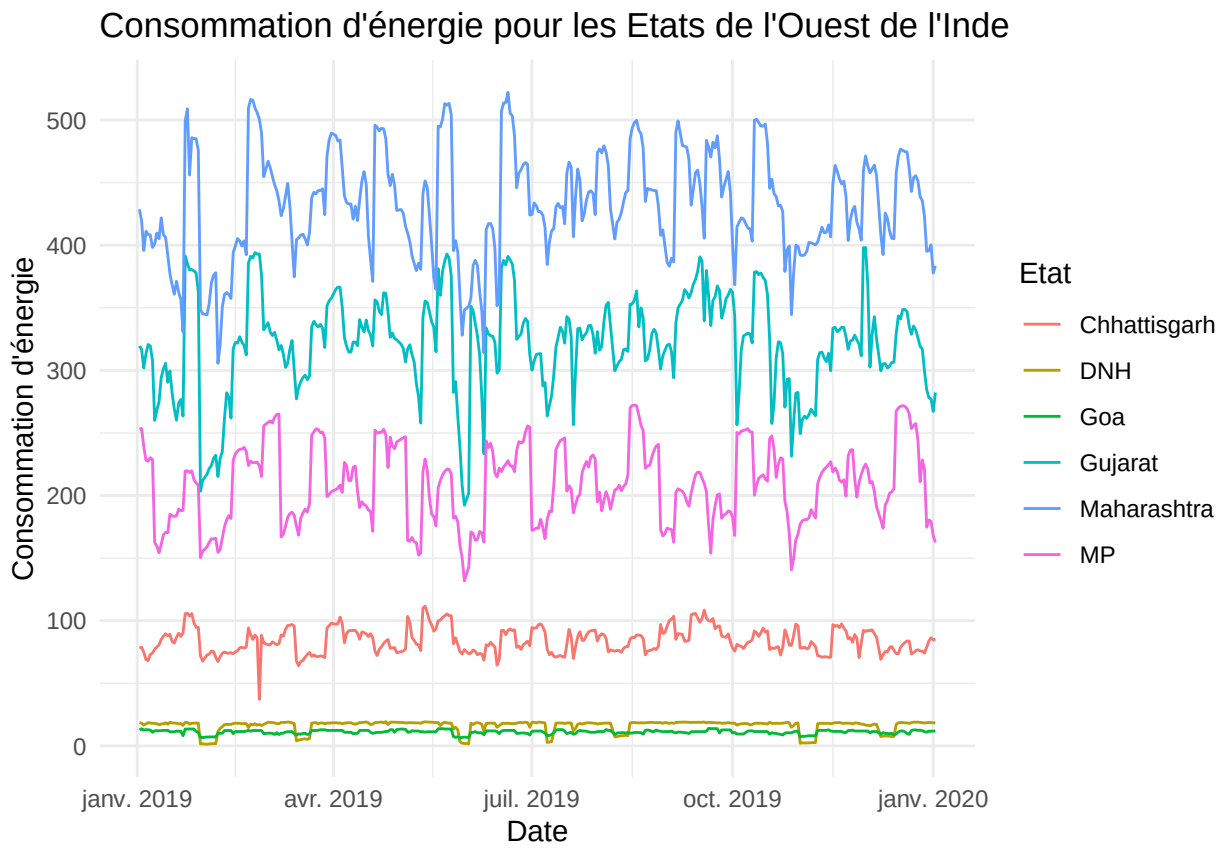

Au sein de chaque région de l'Inde, nous observons de forts contrastes de consommation d'énergie. Nous pouvons noter une différence d'échelle entre les graphiques. Par exemple, dans le Sud de l'Inde, Pondy a une faible consommation d'énergie (entre 4 et 10 mega Units) à l'opposé de Tamil Nadu où sa consommation varie entre 200 et 370 mega Units.

Il serait intéressant de consulter l'avis d'un économiste ou politicien pour analyser et comprendre ces grandes disparités au sein des régions de l'Inde.

Nous construisons le tableau des moyennes de consommation par région :

```
knitr::kable(tapply(data$Consommation, data$Regions, mean),
             "simple", col.names = "moyenne",
             caption = "Tableau des moyennes des consommation d'énergie par région")
```

Table 2: Tableau des moyennes des consommation d'énergie par région

	moyenne
ER	65.935028
NER	6.202789
NR	111.592104
SR	157.457046
WR	178.944710

Nous observons une hétérogénéité en termes de consommation entre les régions de l'Inde. En effet, le Nord-Est a une consommation très faible par rapport à l'Ouest.

Ondelettes

Puisque nos signaux sont irréguliers, notre choix de lissage s'est tourné vers les ondelettes car elles ont des bonnes propriétés de compressions et sont adaptées à ce type de données.

Pour pouvoir poursuivre cette étude, nous avons du transformer notre dataframe de départ pour avoir chaque Etat en colonne avec la valeur de consommation en ligne pour chaque point de mesure.

```
data_long <- data.frame("Etat" = data$Etat,"Date"= data$Date,"Consommation" = data$Consommation)

data_long <- data_long |>
  pivot_wider(names_from = "Etat", values_from = "Consommation")

data_long <- as.data.frame(data_long)
knitr::kable(head(data_long),"simple", caption = "Première ligne du tableau")
```

Date	Punjab	Haryana	Rajasthan	Delhi	UP	Uttarakhand	HP	J&K	Chandigarh	Chhattisgarh	C
2019-01-02	119.9	130.3	234.1	85.8	313.9	40.7	30.0	52.5	5.0	78.7	
2019-01-03	121.9	133.5	240.2	85.5	311.8	39.3	30.1	54.1	4.9	78.8	
2019-01-04	118.8	128.2	239.8	83.5	320.7	38.1	30.1	53.2	4.8	74.8	
2019-01-05	121.0	127.5	239.1	79.2	299.0	39.2	30.2	51.5	4.3	69.0	
2019-01-06	121.4	132.6	240.4	76.6	286.8	39.2	31.0	53.2	4.3	68.1	
2019-01-07	118.0	132.1	241.9	71.1	294.2	40.1	30.1	53.3	4.0	73.1	

Le problème ici est que la longueur des courbes de consommation n'est pas de la forme 2^J. Ces courbes sont de longueur 356, on symétrise le signal à la fin pour atteindre une longueur de 512. On se ramènera à la fin au signal de départ de taille 356.

Nous représentons le signal pour un Etat (ici le Punjab) :

```
i = 2
y <-  data_long[,i]
# y

plot(1:356,y,type="l",main="Signal de départ", ylab = "Consommation", xlab="Jour")
```

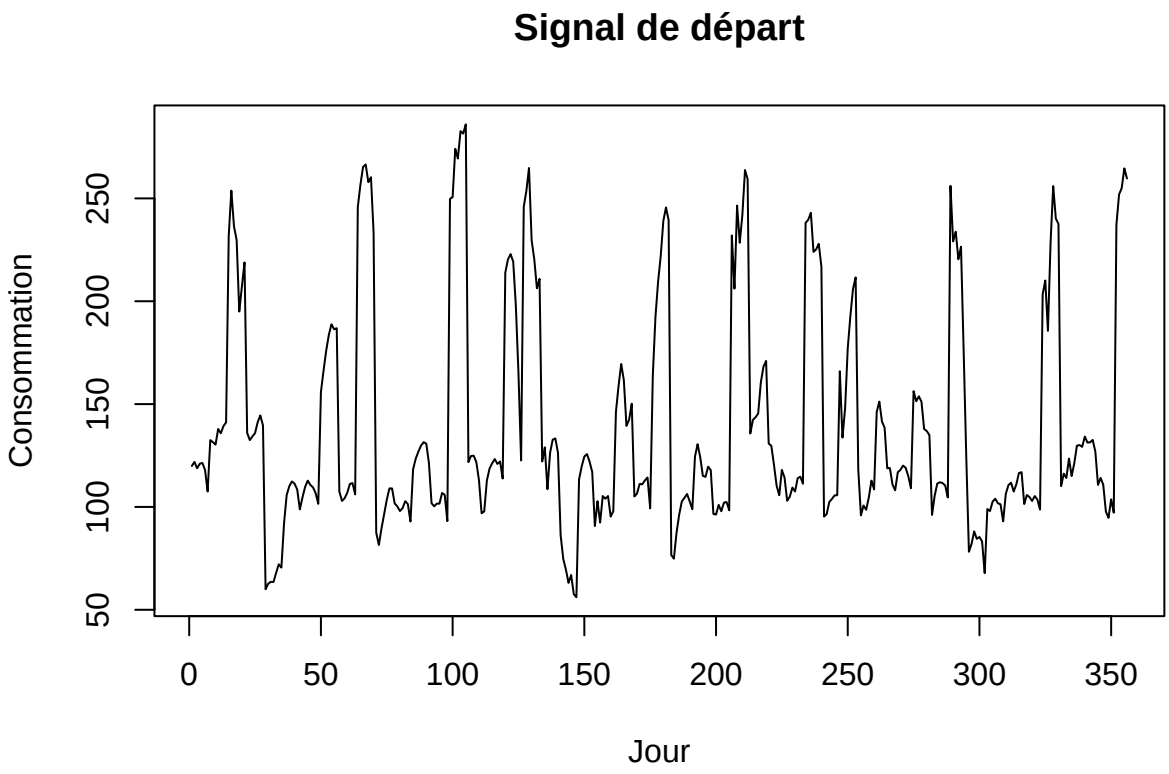


```r
# Créer un signal symétrisé
ysym = c(y, rev(tail(y, n= 512-length(y)))) # on choisit 512 pour avoir une puissance de 2

# Tracer le signal symétrisé
plot(ysym, type = "l", main = "Signal symétrisé", ylab = "Consommation", xlab = "Jour")

# Ajouter une ligne verticale à la position
# axe de symétrie : 361 jours
abline(v = 356, lty = 2)
```

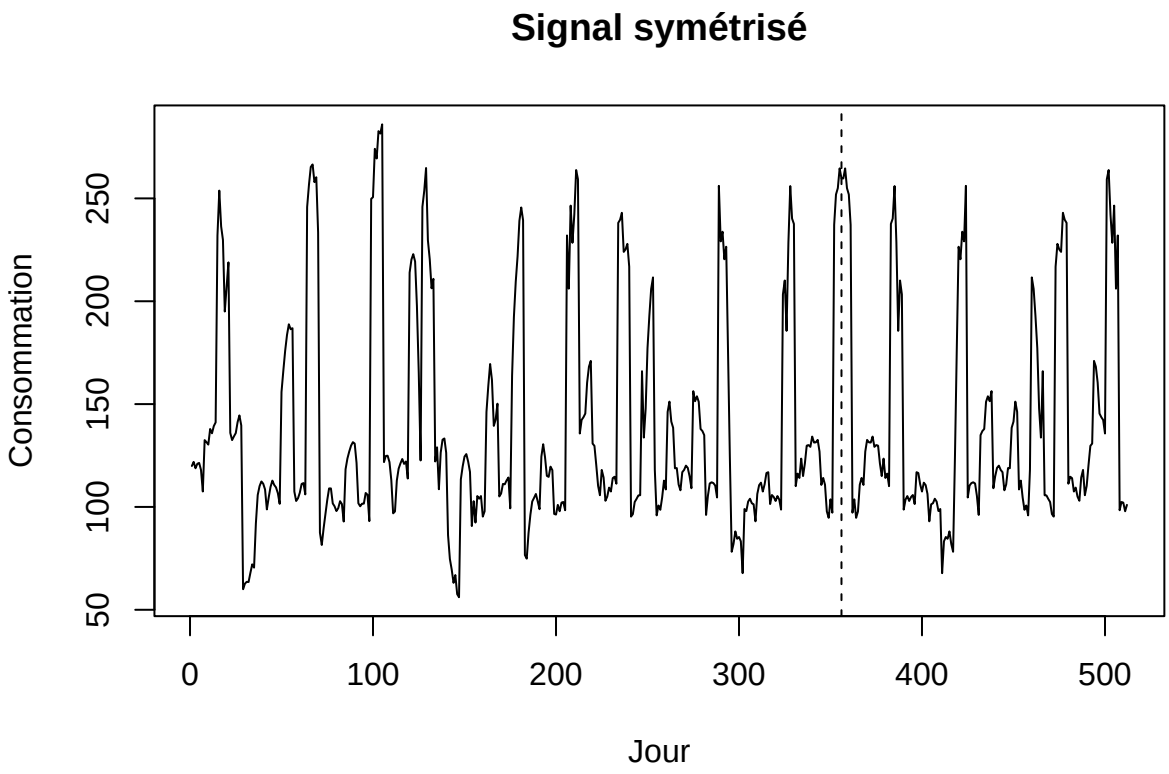

La méthode des ondelettes est complexe et nous ne disposons pas des connaissances nécessaires pour faire une analyse approndie. De plus, il n'est pas possible de réaliser une ACP avec les ondelettes.

Nous nous tournons donc vers le lissage par moindres carrés pénalisés à l'aide des bases de splines

Lissage par moindres carrés pénalisés - Base de Spline

PROPRIETE DES BASES DE SPLINE

Lissage d'une trajectoire

Pour un Etat

Représentation de la consommation d'énergie

```
i = 2
y <- data_long[, 2]
tps <- 1:356
plot(tps,y,type="l", main = "Consommation d'énergie du Punjab")
```

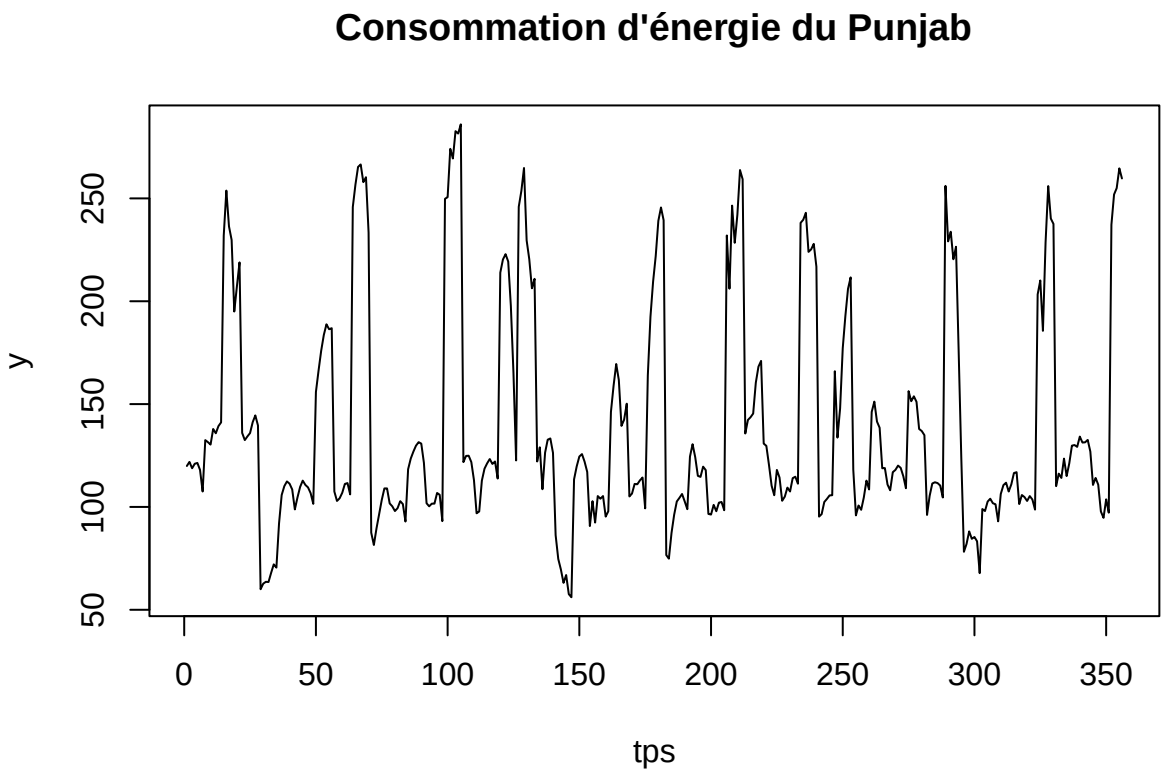


```
i = 10
y <- data_long[, i] # courbe du dixième Etat : Chhattisgarh
tps <- 1:356
plot(tps,y,type="l", main = "Consommation d'énergie du Chhattisgarh")
```

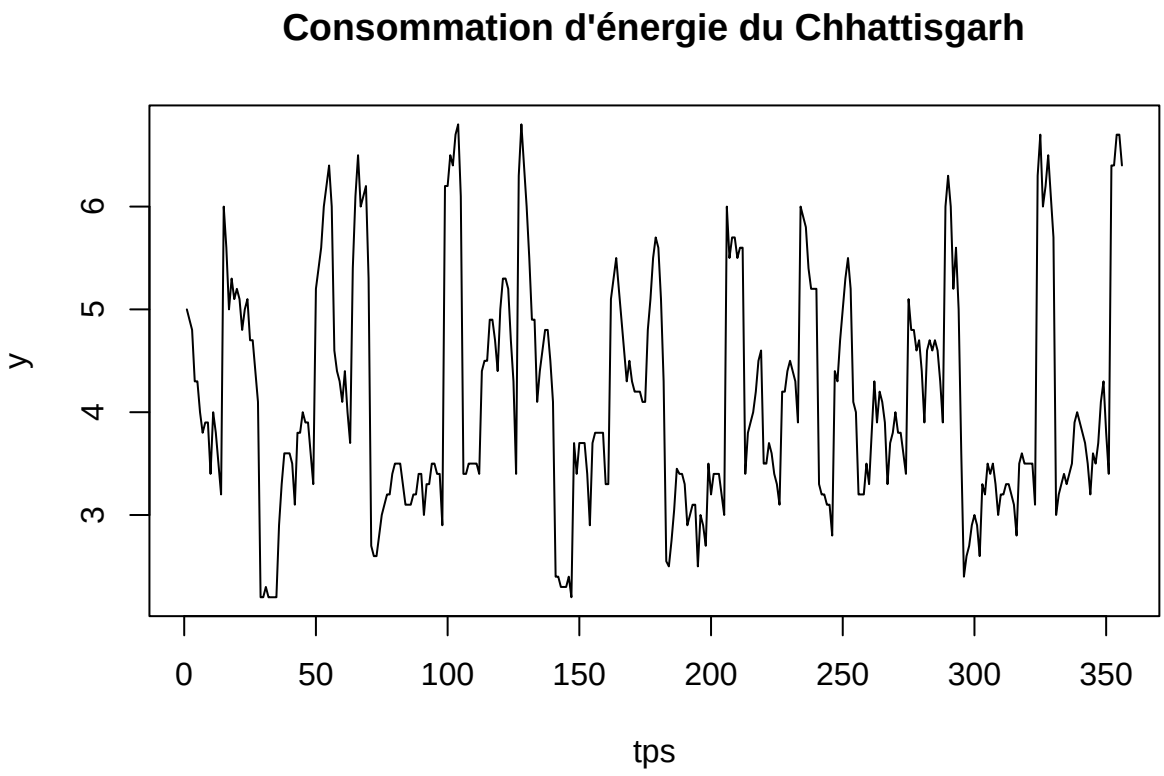

Lissage par moindres carrés pénalisés sur la première courbe

```
splbasis = create.bspline.basis(rangeval = c(1,356),
                                norder=6,
                                breaks=seq(1,356,length=35))
# définition une base de B-spline entre 1 et 356 (les dates)
# ordre 4 (classique)
# breaks : coupure


plot(splbasis)
```

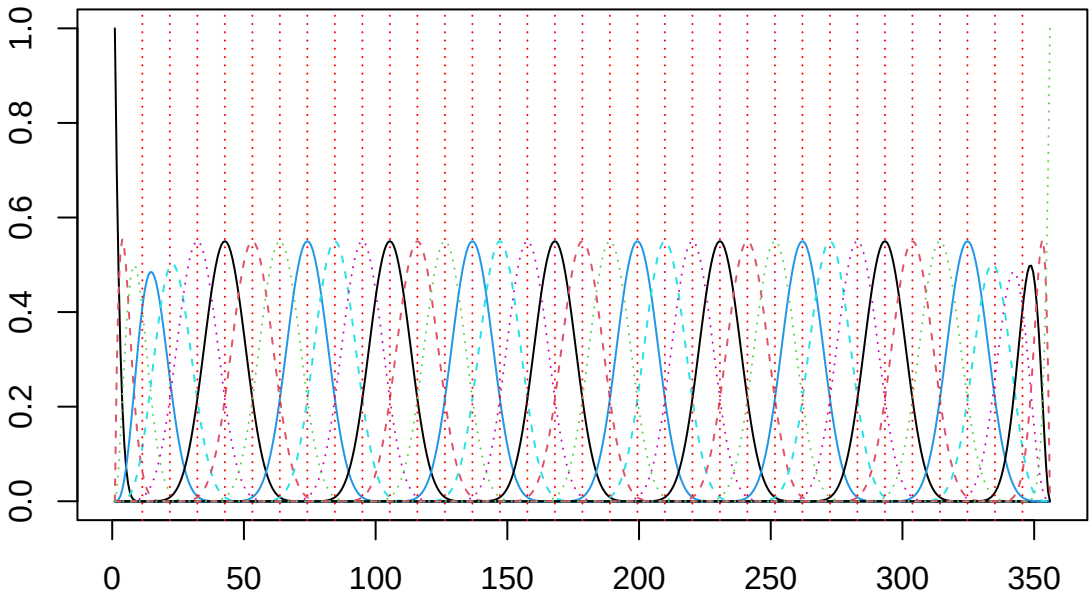


```
summary(splbasis)
```

```
##
## Basis object:
##
##   Type:   bspline
##
##   Range:  1  to  356
##
##   Number of basis functions:  39
```

Il s'agit d'une base de type "bspline" ce qui signifie qu'elle utilise les fonctions B-splines pour modéliser les données. Dans cette base, il y a 39 fonctions de base, utilisées pour construire la représentation fonctionnelle des données.

La plage des données s'étend entre 1 et 356, correspondant à nos temps de mesure.

```
i = 2
y = data_long[,i]
gcv = 1:30 # grille de lambda
for (i in 1:30){
  lambda = exp(i-10)
  fdpar= fdPar(splbasis,Lfdobj =4,lambda=lambda)
  smoothdata = smooth.basis(tps,y,fdParobj = fdpar)
  gcv[i] = smoothdata$gcv
```

```
}
plot(gcv)
```

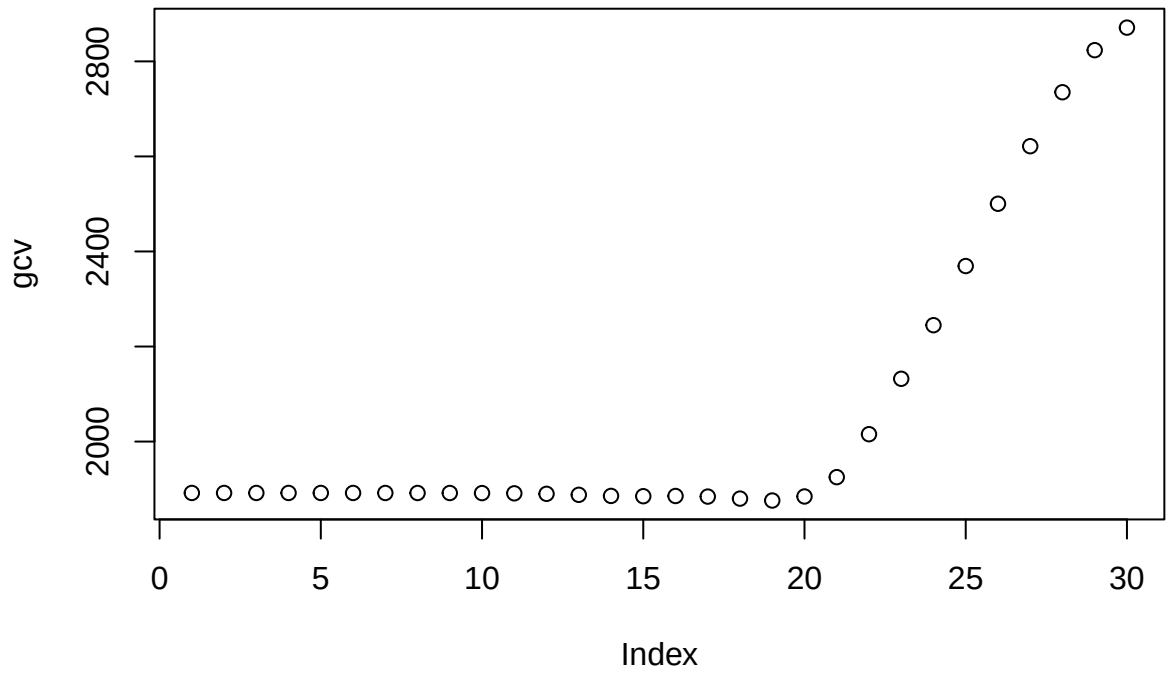


```
which.min(gcv)
```

```
## [1] 19
```

Nous obtenons une valeur de lambda égale à 19 pour l'Etat du Punjab.

Nous évaluons notre base de spline avec cette valeur optimal de lambda.

```
lambda = exp(which.min(gcv)-10)
fdparTemp = fdPar(splbasis,Lfdobj = 4,lambda=lambda)
smoothdata = smooth.basis(tps,y,fdParobj = fdpar)
```

Nous représentons sur un même graphe les observations et la fonction estimée reconstruite ^f.

```
plotfit.fd(y,# valeur de consommation pour un pays
           tps, # les dates
           smoothdata$fd, # nos données estimées
           # 1 à 356
           pch=20,
           cex=0.5,
           main="les observations et la fonction estimée reconstruite ^f",
```

```
        ylab = "consommation d'énergie",
        xlab="temps")
```

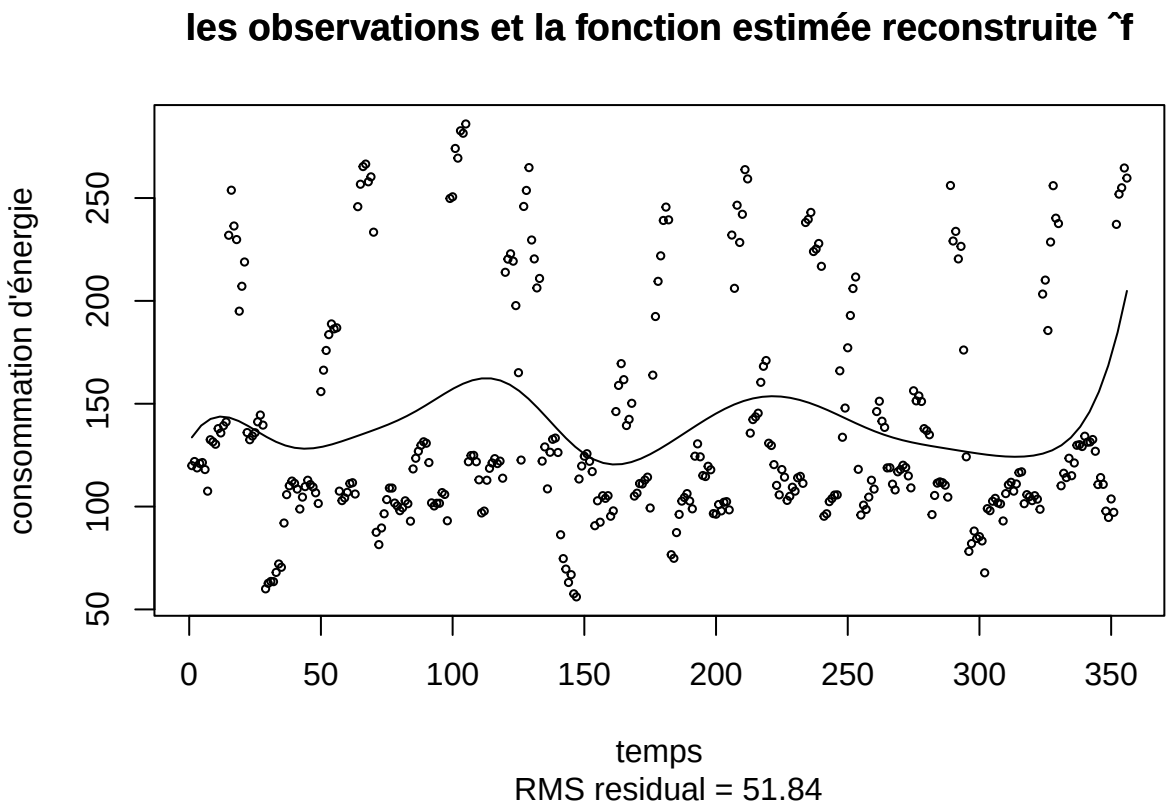

Nous obtenons une fonction estimée lisse pour l'Etat du Punjab, beaucoup moins irrégulière que nos données de base, et qui explique le comportement de la consommation d'énergie du Punjab sur une année.

Nous représentons la dérivée première et la dérivée seconde sur le même graphique :

```
fhatprim = eval.fd(tps,smoothdata$fd,Lfdobj=1)
fhatpprim = eval.fd(tps,smoothdata$fd,Lfdobj=2)
matplot(tps,cbind(fhatprim,fhatpprim),type="l")
```

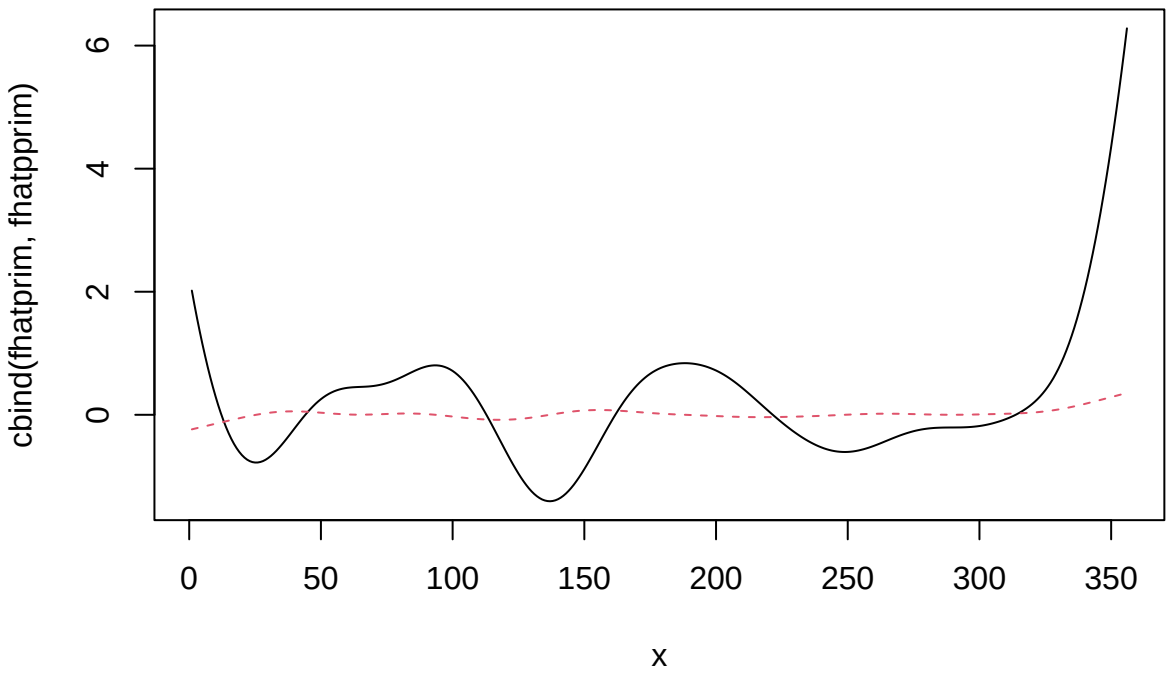

La dérivée première en noir, qui correspond à la vitesse de croissance, n'est pas très lisse et indique donc que par moment dans l'année, la consommation d'énergie diminue ou augmente rapidement. Par exemple au niveau du 20ème et 140ème jour, sa consommation d'énergie décroit rapidement. A la fin de l'année, celle-ci explose.

Les dérivées obtenues sont régulières (on a pris une base d'ordre plus élevé, égal à 6) et le lissage est contraint par la rugosité de la dérivée seconde avec une pénalité sur la dérivée d'ordre 4.

Pour l'ensemble des Etats

Lissage par moindre carrés pénalisés

On fait l'ajustement pour différentes valeurs de lambda pour minimiser le critère de pénalité.
On veut la fonction la plus proche des points et la moins oscillante grâce à la pénalité

```
# Initialisation d'une grille de lambda
gcv = rep(0,30)

for (i in 1:30){
  lambda = exp(i-10)
  fdpar = fdPar(splbasis,Lfdobj = 4,lambda=lambda)
  smoothdata = smooth.basis(tps,as.matrix(data_long[,c(-1)]), fdParobj = fdpar)
  gcv[i] = mean(smoothdata$gcv)
}
plot(gcv)
```

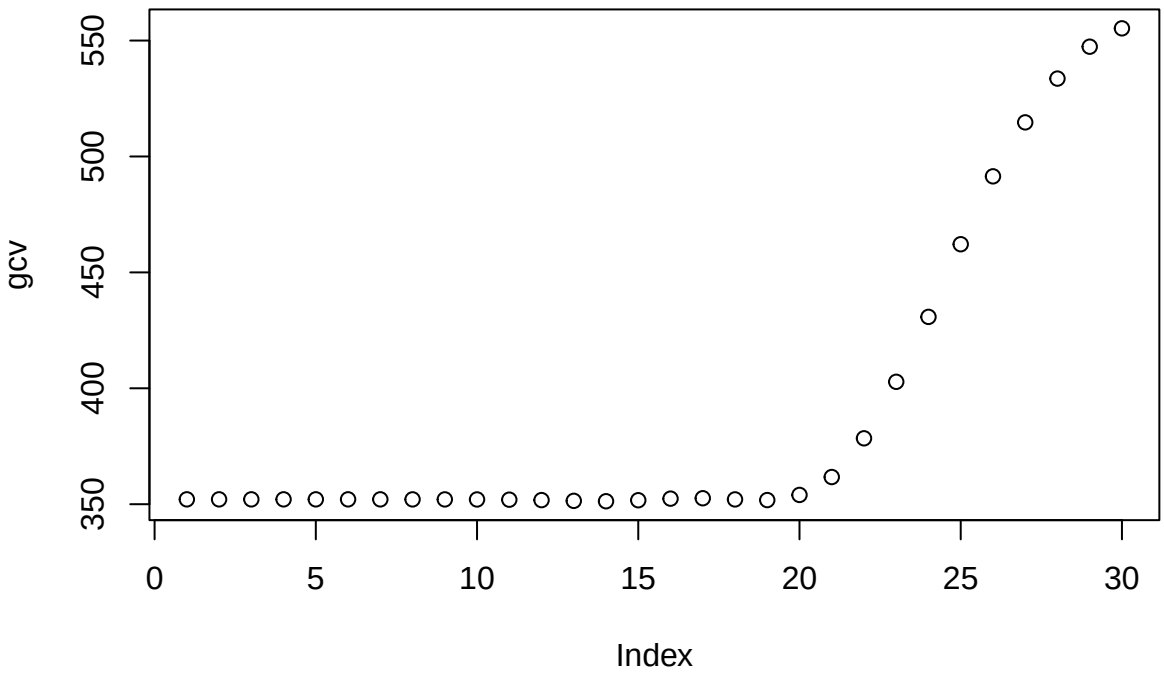


```
which.min(gcv)
```

```
## [1] 14
```

Nous avons observé que la valeur optimale de lambda est la 14ème valeur, correspondant au minimum. Cette valeur nous permettra d'être proche des données observées.
Nous avons choisi de paramétrer le nombre de coupures à 35 car les signaux sont très irréguliers et nous souhaitons être proche, mais raisonnablement, du signal d'origine. Ce choix est arbitraire car il peut engendrer du sur-apprentissage si le nombre de coupures est trop élevée par rapport au signal de départ.

Nous allons recalculer la pénalité et refaire le lissage avec la valeur de lambda minimale :

```
lambda = exp(which.min(gcv)-10)
fdpar = fdPar(splbasis,Lfdobj = 4,lambda=lambda) # calcul pénalité
smoothdata = smooth.basis(tps,as.matrix(data_long[,c(-1)]),fdParobj = fdpar) # lissage
```

Nous évaluons notre objet fonctionnel à chaque point de temps :

```
fhatsmooth <- eval.fd(tps, smoothdata$fd)
```

Représentation pour l'ensemble des Etats

Nous représentons les observations et la fonction estimée reconstruite ^f.

```
matplot(tps,data_long[,c(-1)],type="l",lty=1,ylab="",main="donnees brutes")
```

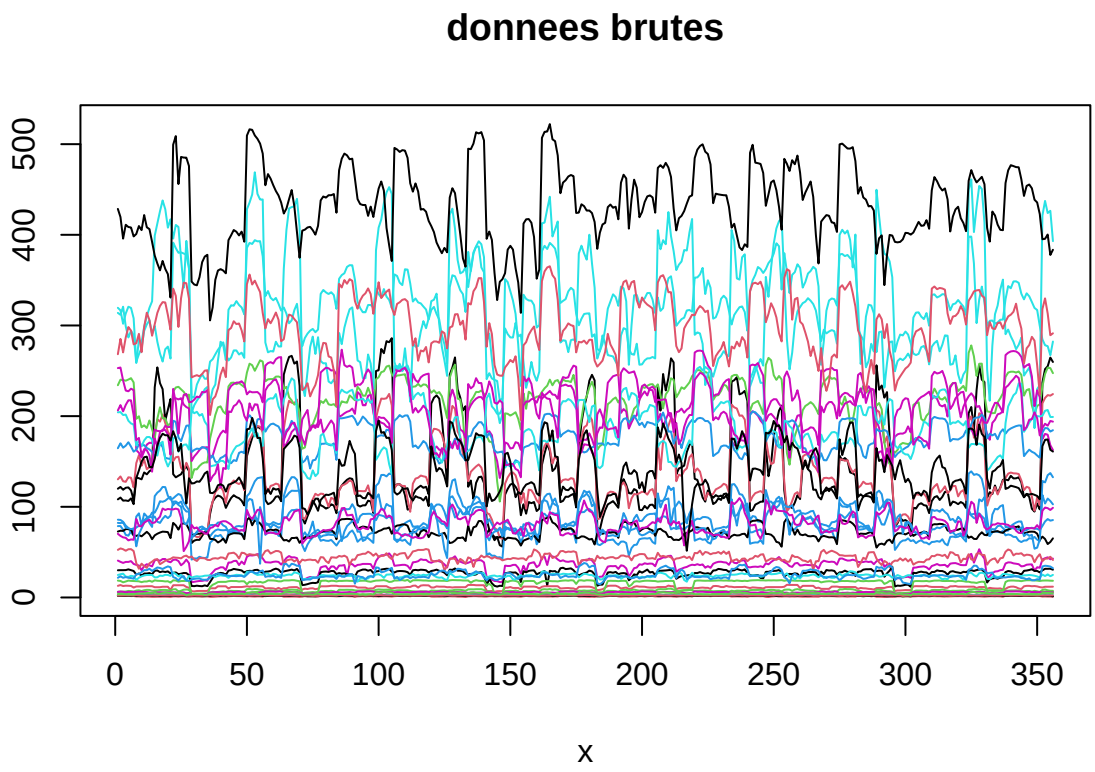


```
matplot(tps,fhatsmooth,type="l",lty=1,ylab="",main="donnees lissees")
```

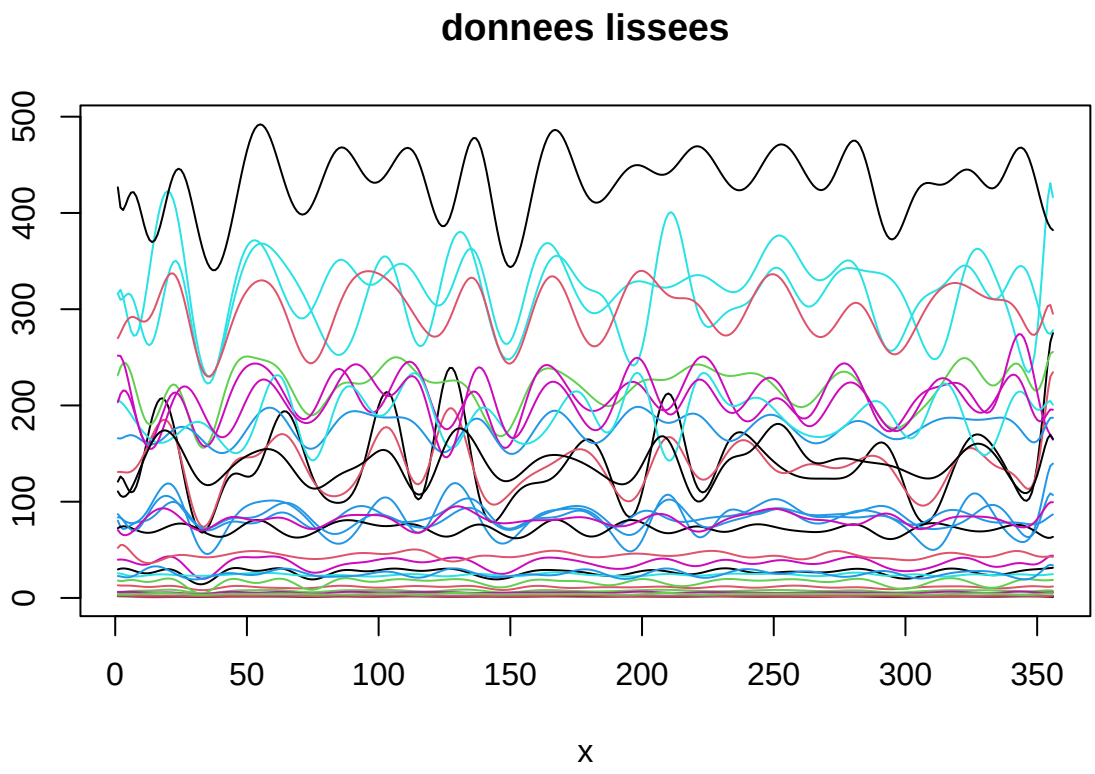

Nous obtenons des courbes lissées, moins irrégulières, qui explique bien la tendance de la consommation d'énergie pour chacun des Etats.

Lors de la création de notre base de spline, nous avons choisi 35 coupures, ce qui biaise forcément notre analyse. Avec ces courbes lissées, les analyses ne sont pas exhaustives pour éviter le sur-apprentissage. Avec ces courbes, nous pouvons supposer qu'il y a plus de variabilité en hiver qu'en été.

Nous représentons maintenant la dérivée première et seconde pour étudier les vitesses de croissance et les accélérations de croissance.

```
fhatprim = eval.fd(tps,smoothdata$fd,Lfdobj=1) # dérivé première
fhatpprim = eval.fd(tps,smoothdata$fd,Lfdobj=2) # dérivé seconde
matplot(tps,
        fhatprim,
        type="l",
        main = "Dérivée première")
```

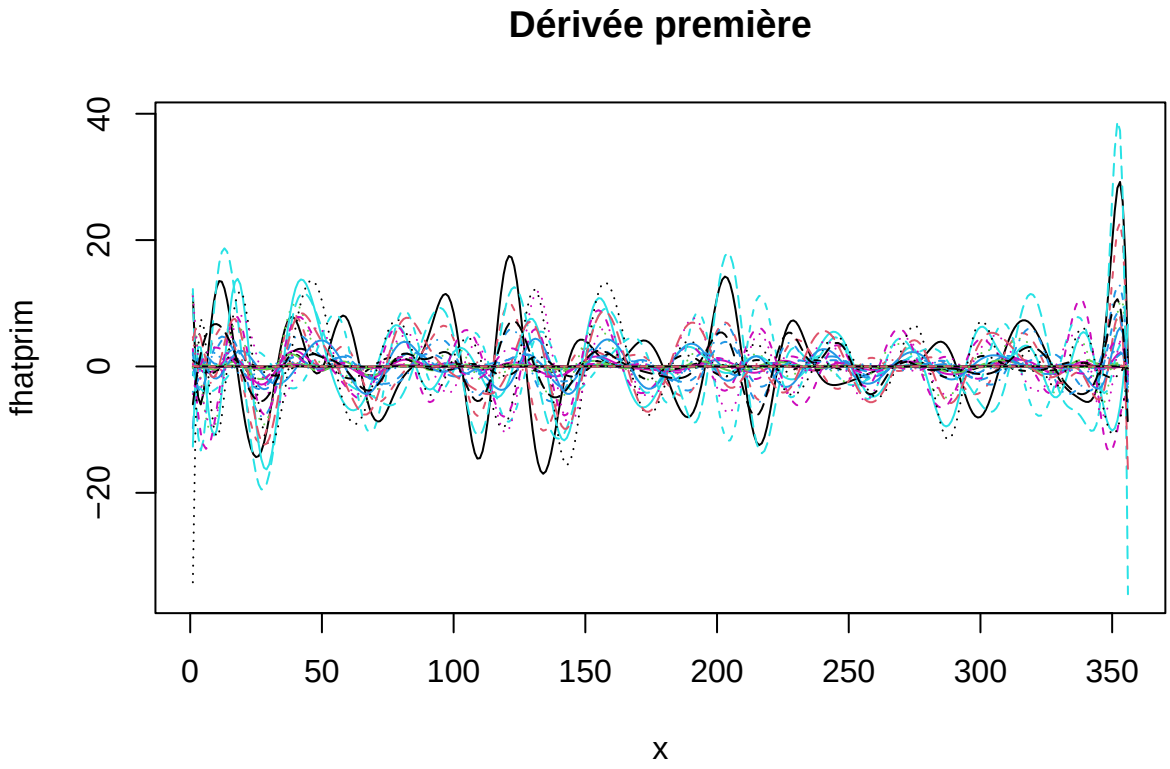


```
matplot(tps, fhatpprim, type = "l",
        main = "Dérivée seconde")
```

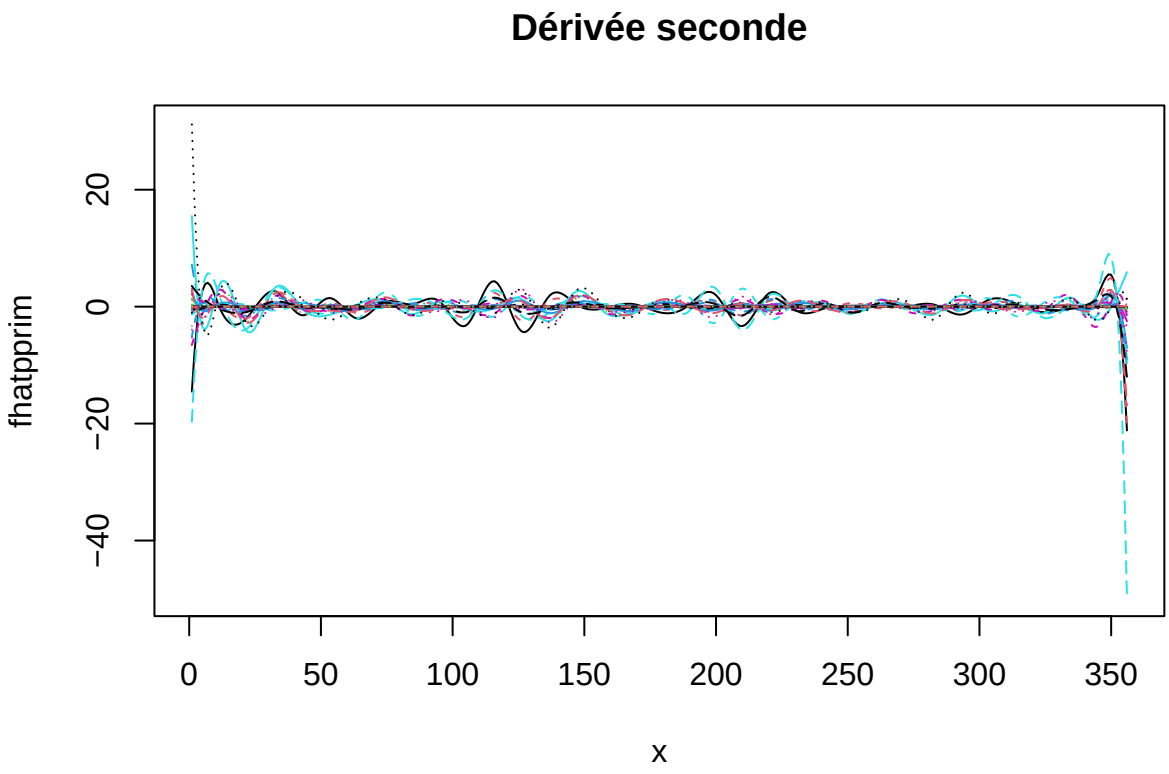

Statistiques exploratoire

Moyenne fonctionnelle

Afin de visualiser les tendances, nous allons représenter la moyenne de notre objet fonctionnel.

```
mean_smooth_data = mean.fd(smoothdata$fd)
# mean_smooth_data
```

```
matplot(fhatsmooth,col="gray",type="l",
        xlab="jours",
        ylab="Consommation d'énergie",
        main = "Consommation d'énergie des Etats d'Inde, \n avec tracé de la moyenne"
        )
lines(mean_smooth_data,lwd=2) # moyenne
```

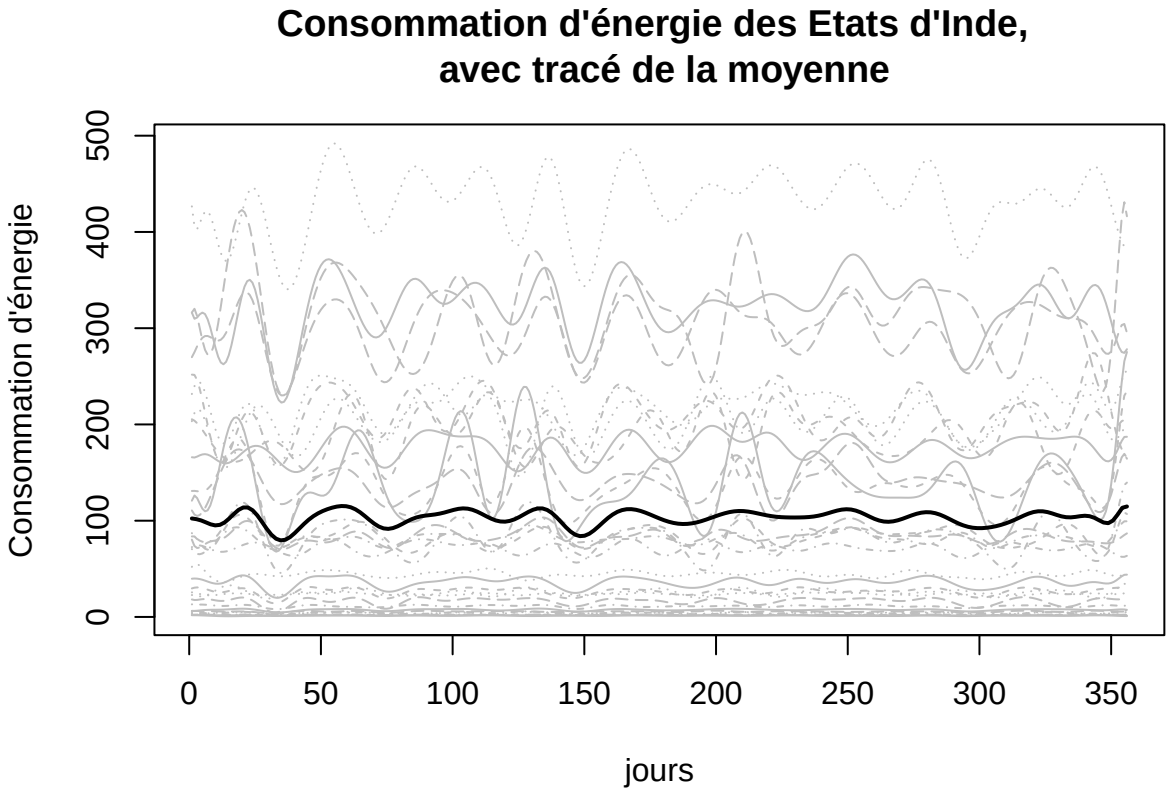

Grâce à ce graphique, nous pouvons observer la courbe moyenne de la consommation d'énergie dans les différents Etats d'Inde. Les valeurs de consommations sont situées aux alentours de 100 Méga Units.
Cette courbe est influencée par les valeurs extrêmes car nous pouvons observer un grand nombre de courbes avec des valeurs plus faibles de consommation.

Ecart-type fonctionnel

La représentation de l'écart-type fonctionnel permet de caractériser la variabilité de nos signaux sur la période étudiée.
Nous allons pouvoir identifier s'il existe des périodes de stabilité ou d'instabilité entre le début et la fin de l'année 2019.
Aussi, nous allons pouvoir comparer les différents Etats pour analyser d'éventuels similarités ou différences.

```
sd_smooth_data= sd.fd(smoothdata$fd)
```

```
matplot(fhatsmooth,
        col="gray",type="l",
        xlab="jours",
        ylab="Consommation d'énergie",
        ylim = c(-200,500))
fnmoy = eval.fd(y,mean_smooth_data)
fnsd  = eval.fd(y,sd_smooth_data)
lines(fnmoy,lwd=2)
lines(fnmoy+2*fnsd,lwd=2,col=4,lty=2)
lines(fnmoy-2*fnsd,lwd=2,col=4,lty=2)
```

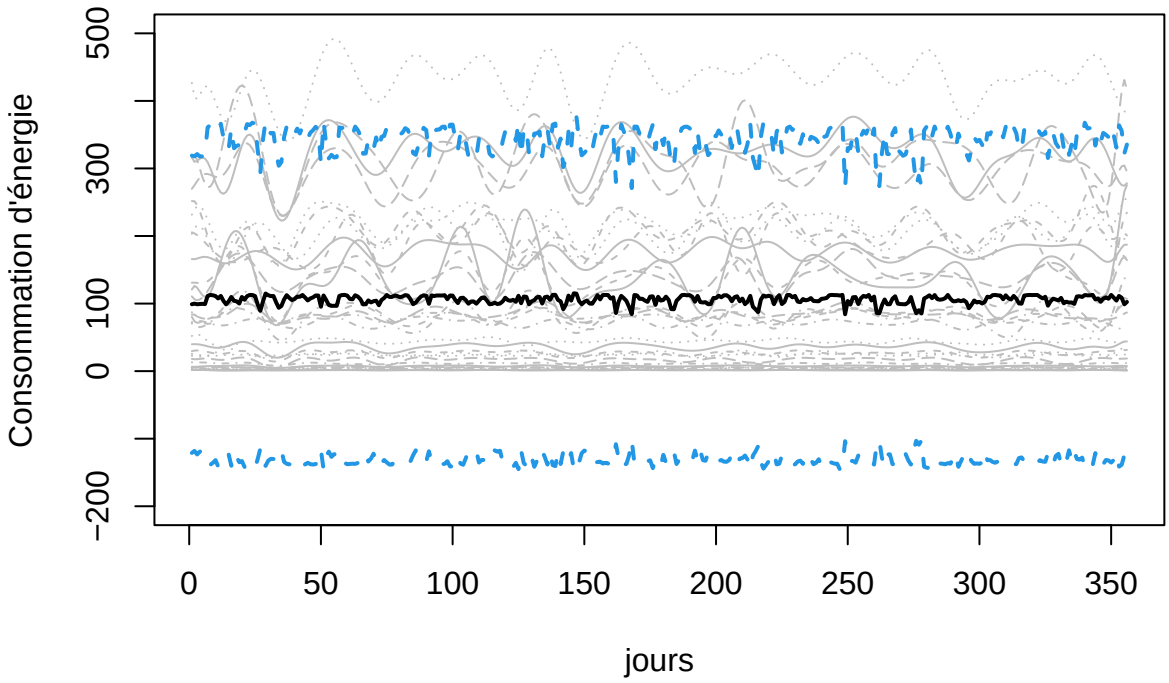

Ce graphique nous permet de visualiser les consommations d'énergie (données lissées) des différents Etats en Inde. La courbe moyenne, en noir, nous permet d'avoir une idée de la tendance centrale. La plage de variabilité est définie par les pointillés en bleus, correspondant à la moyenne plus (ou moins) 2 fois l'écart-type.
La majorité des pays présentent donc des données lissées proches de la moyenne. Nous pouvons identifier quelques Etats atypiques.

Surface de covariance et corrélation

Afin d'explorer les relations et les dépendances entre nos différents Etats.

Covariance

Dans un premier temps, nous allons mesurer comment les consommations des Etats évoluent conjointement en fonction du temps.

```
cov = var.fd(smoothdata$fd)
surfcov = eval.bifd(seq(1,356,length=35),seq(1,356,length=35),cov)
```

Pour le tracé d'une surface, il est préférable de choisir un nombre modéré de points dans la grille d'évaluation (la représentation est rapidement illisible dans le cas contraire). Ici, nous choisissons arbitrairement 30 points répartis entre 1 et 356.

```
persp(surfcov,col="gray",theta=30,xlab="jours",ylab="jours",zlab="covariance")
```

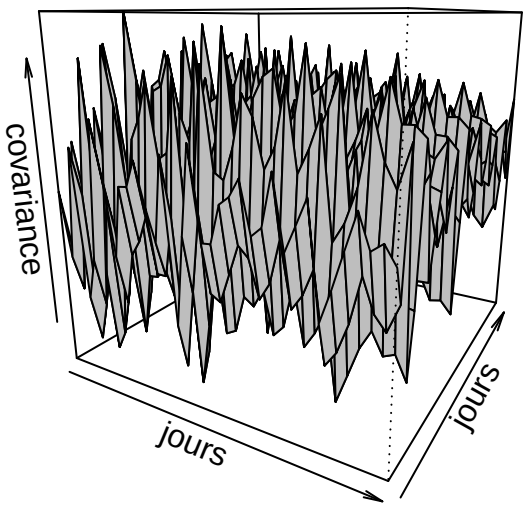

L'analyse de cette représentation est assez compliquée car elle permet de visualiser la covariance entre les différentes consommations des Etats selon les jours, mais aucune tendance claire ne se dégage.

```
contour(surfcov)
```

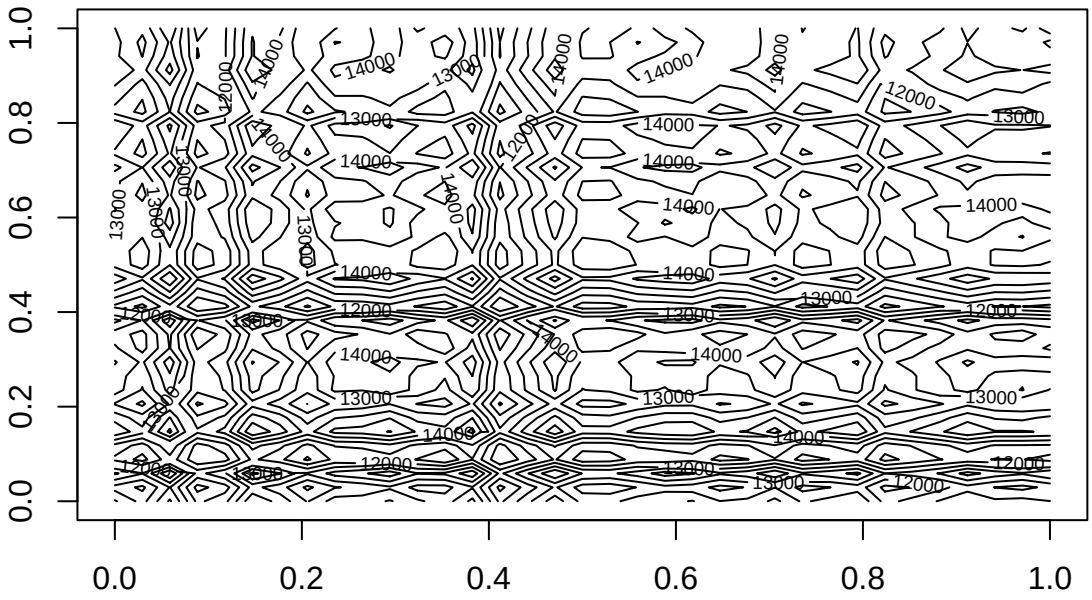

De même, cette représentation devraient pouvoir nous aider pour identifier la covariance entre les consommations d'énergie des Etats selon les jours mais il est presque illisible.

Représentation graphique en couleur

```
filled.contour(surfcov)
```

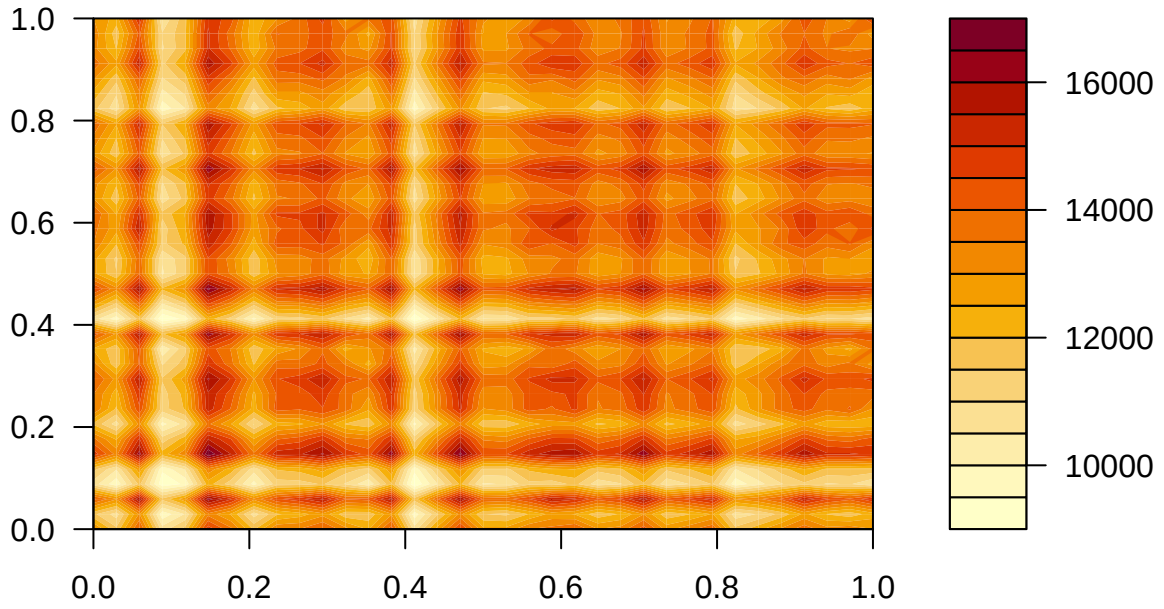

En général, on peut voir que la covariance est “moyenne” entre le début et la fin de l’année pour chaque Etat. Nous pouvons observer des moments où la covariance est moins importante, autour du mois d’Avril (0.4) et de Septembre (0.8).

Corrélation

L’analyse de la corrélation nous permet de détecter si nous avons des effets d’un jour à l’autre sur la consommation d’Energie dans les divers Etats d’Inde.

Nous construisons d’abord la matrice de corrélation :

```
cor = cor.fd(seq(1,356,length=35),smoothdata$fd)
# cor
```

Cette manipulation nous permet de récupérer la matrice de corrélation empirique évaluée (sur les données lissées) en chaque point de temps (jour).

Nous allons représenter graphiquement la matrice de corrélation :

```
persp(cor,col="gray",theta=90,
      phi=40,xlab="jours",
      ylab="jours",zlab="corrélation")
```

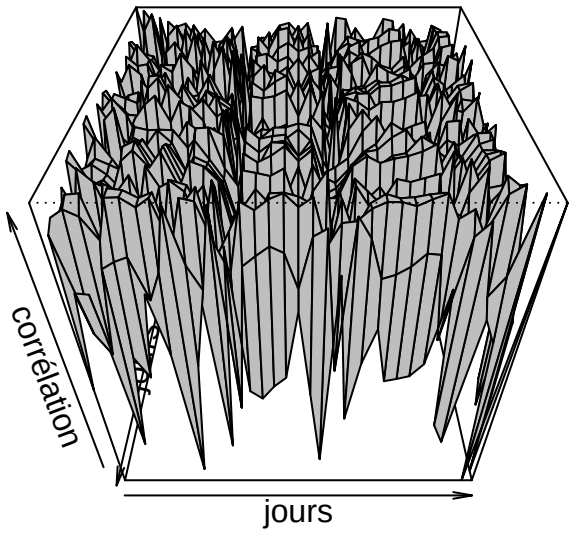

La corrélation est difficilement interprétable sur le graphe, nous allons essayer une autre méthode.

Représentation graphique en couleur

```
filled.contour(cor)
```

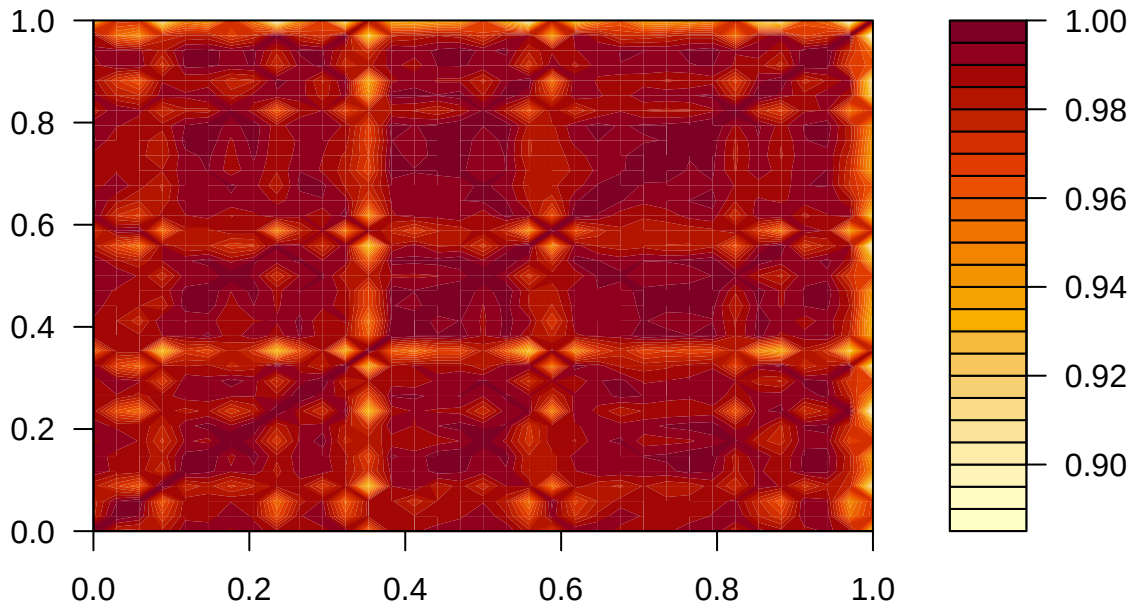

Nous pouvons observer une corrélation égale à 1 sur la diagonale car la consommation d'un jour est forcément corrélée avec elle-même.
De plus, nous pouvons voir que les corrélations sont globalement fortes d'un jour à l'autre, ce qui signifie que la consommation de la veille influence celle du lendemain.

ACP fonctionnelle

```
ACPF = pca.fd(smoothdata$fd,nharm=4,centerfns = TRUE)
ACPF$varprop
```

```
## [1] 0.987179812 0.008252207 0.001454582 0.001198720
```

```
cumsum(ACPF$varprop)
```

```
## [1] 0.9871798 0.9954320 0.9968866 0.9980853
```

La première composante explique environ 99% de la variabilité.

Représentations des composantes principales

Nous représentons en premier lieu les composantes principales obtenues

```
plot(ACPF$harmonics)
```

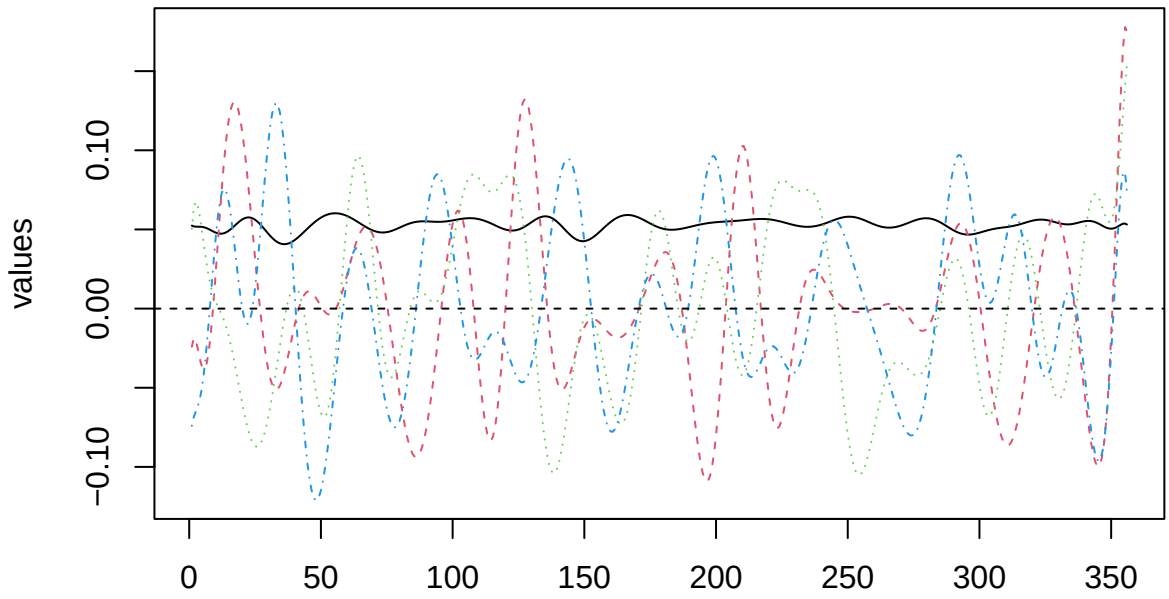


```
## [1] "done"
```

La première composante (en noir) est tout le temps positive. Globalement, elle a quelques variations, environ au 30ème, 140ème et 280ème jour de l'année. Elle a donc tendance à être plus élevé en hiver.

Pour une interprétation plus aisée, on représente la moyenne augmentée ou diminuée des premières fonctions propres.

On peut utilisée la fonction `plot.pca.fd` pour cette représentation.

```
plot.pca.fd(ACPF)
```

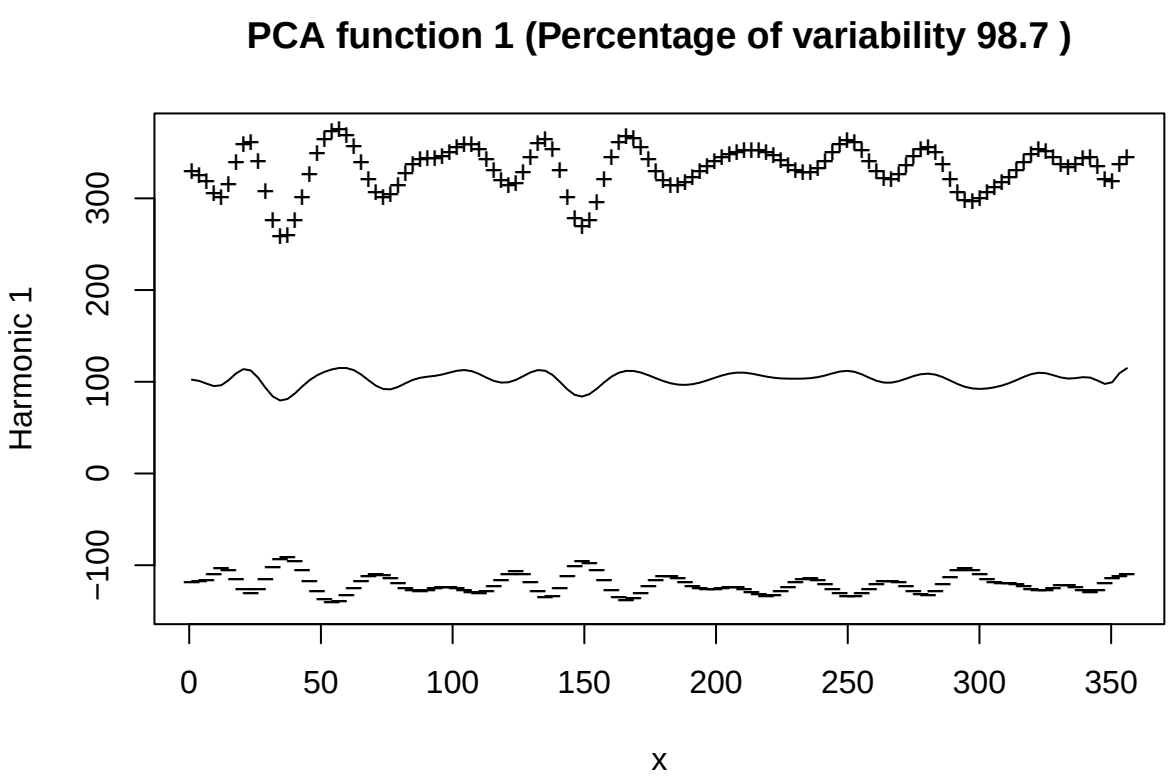
PCA function 1 (Percentage of variability 98.7)
Harmonic 1
−100
0
100
200
300
0
50
100
150
200
250
300
350
x

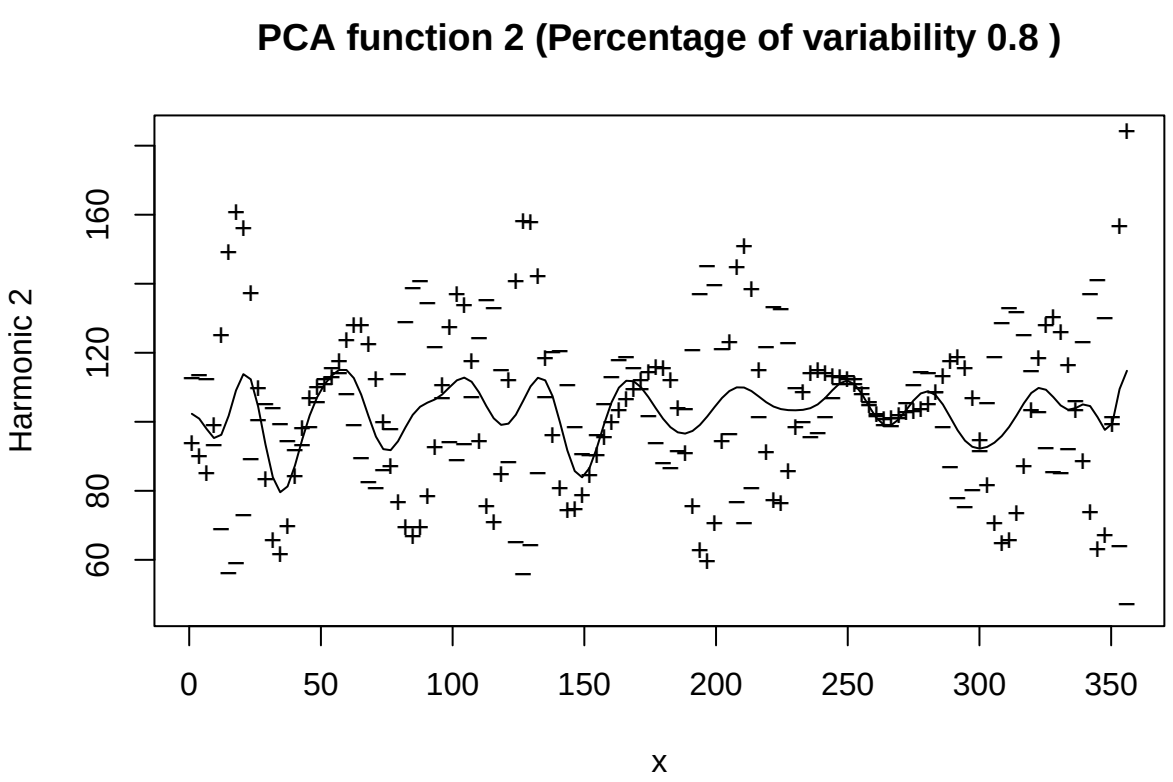
PCA function 2 (Percentage of variability 0.8)
Harmonic 2
60
80
120
160
0
50
100
150
200
250
300
350
x

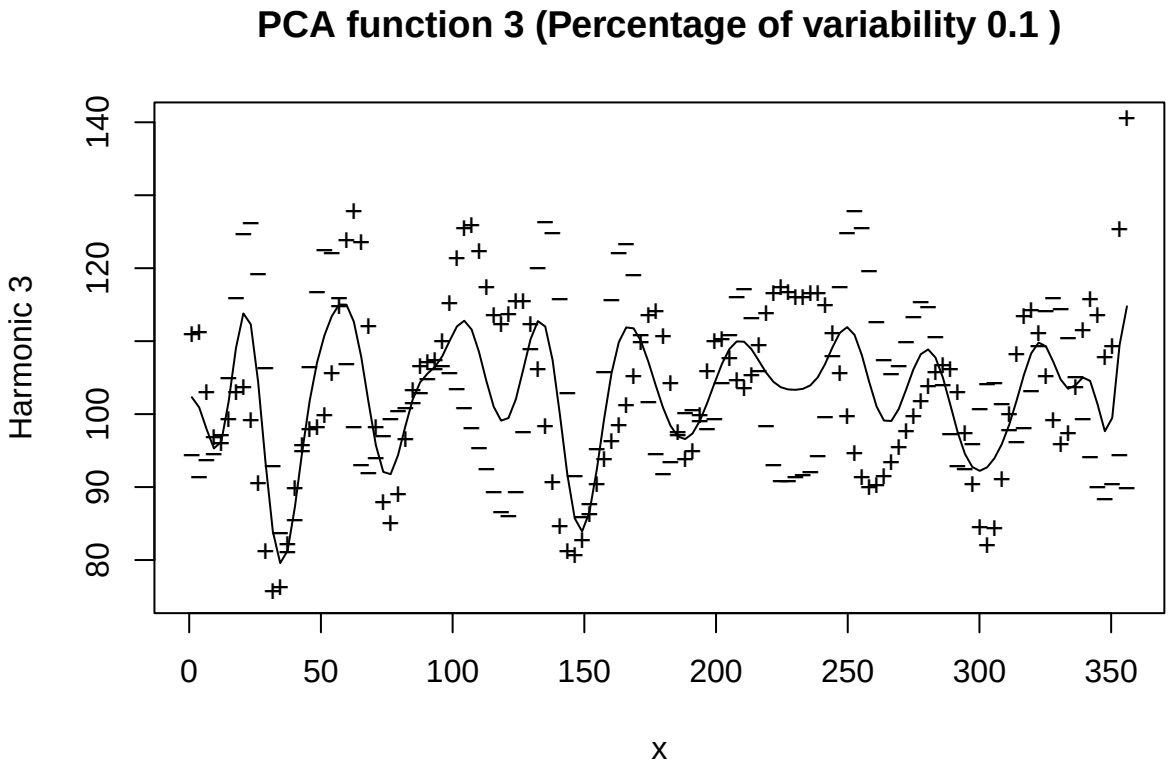
PCA function 3 (Percentage of variability 0.1)
Harmonic 3
80
90
100
120
140
0
50
100
150
200
250
300
350
x

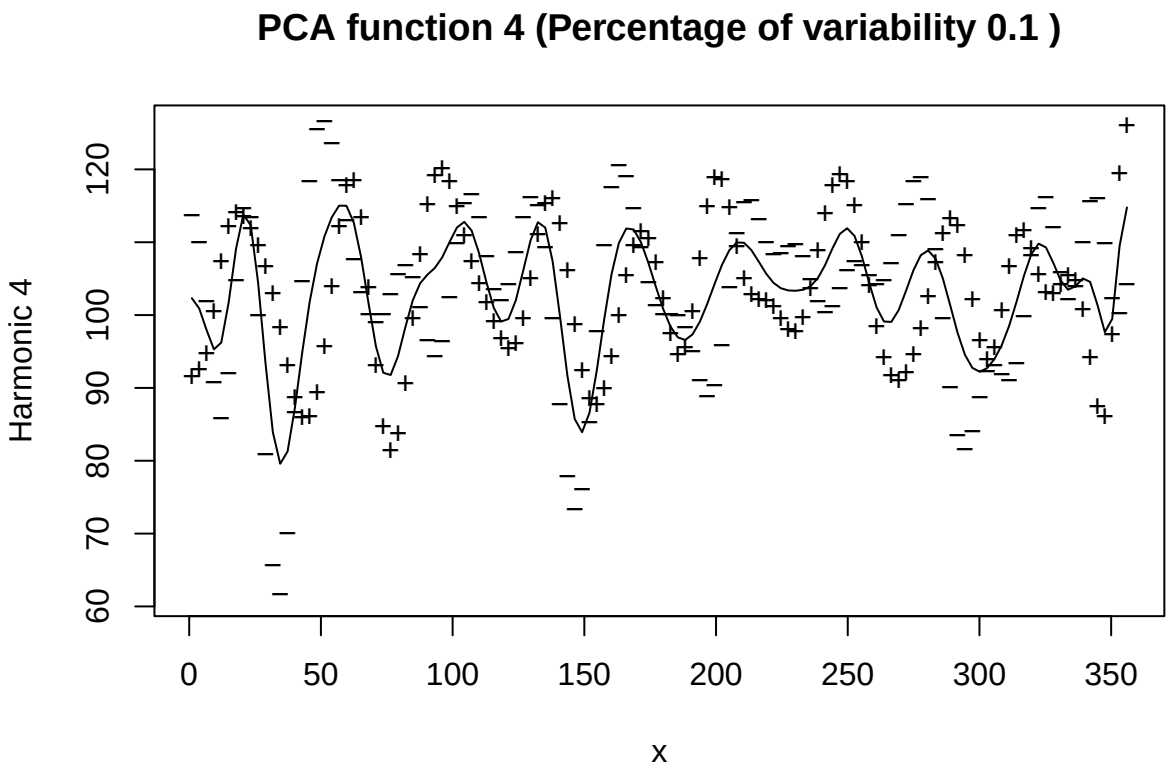

Pour la première fonction propre:

- La courbe en noir représente la moyenne
- La courbe avec des "-" représente la moyenne - alpha * la première composantes principales
- La courbe avec des "+" représente la moyenne + alpha * la première composantes principales

Comme évoqué précédemment, nous pouvons supposer qu'il y a plus de variabilité en hiver qu'en été.

Représentation des individus

Représentation des individus dans le premier plan factoriel

Les scores des individus sont stockés dans la matrice `scores` de `ACPF`. Nous allons les représenter sur le premier plan factoriel.

```
head(ACPF$scores)
```

```
##            [,1]      [,2]       [,3]        [,4]
## [1,]   694.4987 574.65950  211.59702   -1.507536
## [2,]   652.9611 341.00037  133.02690  -38.626858
## [3,]  2182.0635 -35.48669  162.31803 -138.399753
## [4,]  -380.1501 242.24678  -11.92453  -35.326778
## [5,]  4004.6725 595.76303 -146.66314   12.226365
## [6,] -1259.7014  -5.22891    1.44213  -34.825769
```

```
plot(ACPF$scores[,1],
     ACPF$scores[,2],
     pch=20,
     xlab="FPC 1",
     ylab="FPC 2",
     type="n")
nomsvilles = colnames(data_long[,c(-1)])
regions = as.factor(data$Regions)
text(ACPF$scores[,1],
     ACPF$scores[,2],
     labels=nomsvilles,cex=0.7,col=as.numeric(regions))
legend("topleft",legend = levels(regions),col=1:4,lty=1)
```

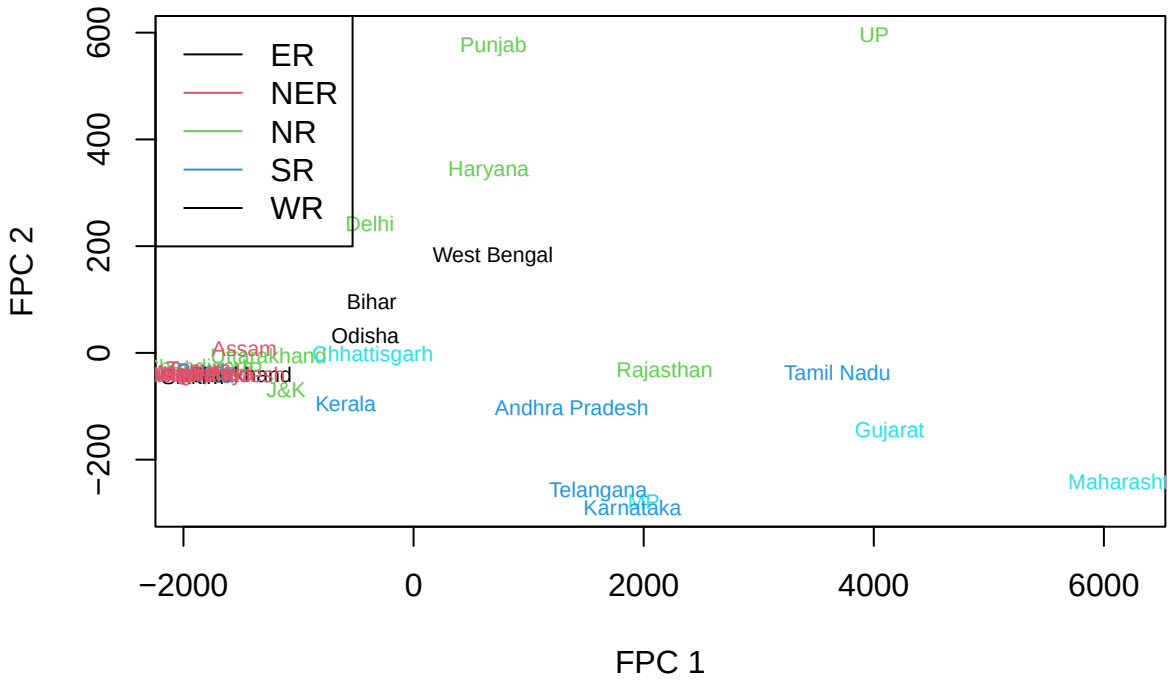

Aucune région ne semble se distinguer concernant les consommations d'énergie des Etats. Cependant, nous observons quelques exceptions comme la région NR (Nord) où quelques Etats présentent des valeurs assez élevées sur le second axe factoriel contrairement à la région SR (Sud) où les valeurs sont plutôt faibles.

Pour la première compostante principale (abscisse), les Etats concentrés à droite du graphique présentent des valeurs de consommations d'énergie élevées. Par exemple, Maharashtra et l'Etat du Gujarat sont des grands consommateurs d'énergies. Pour les petites valeurs, les Etats présentent des consommations plus faibles. Cette observation est en adéquation avec les premières représentations graphiques que nous avons réalisées au début de ce rapport.

Pour la deuxième composante principale (ordonnée), pour les Etats situés en haut du graphique, cela indique que leur consommation d'énergie est très variable selon les périodes de l'année. L'Etat du Punjab et Uttar Pradesh (UP) présentent beaucoup d'écarts de valeurs. Pour les petites valeurs, cela signifie que les Etats ont des consommations d'énergie plus stables entre le début et la fin de la période étudiée.

Sources

- base de données : https://www.kaggle.com/datasets/twinkle0705/state-wise-power-consumption-in-india?fbclid=IwAR3tNVrXpTrRlO_HVOoa53bcaTR8aR7QU_Nlbe4AhhmfzdK9ERa5Xxid1yk
- nombre d'habitants par pays : https://fr.zhujiworld.com/in/673630-tripura/?fbclid=IwAR2Ua_lx2k7u-Nil065Pw0S0mK682X7e8AuvR5CS7lfpsbUBPIlEzNiwE2Q